

基于 sEMG 的连续膝关节角度预测方法

唐晓娅 陈 峰

(南通大学电气工程学院 江苏 南通 226019)

摘 要 建立表面肌电信号(surface electromyography, sEMG)和关节运动量的映射模型,对康复机器人的连续运动过程控制具有重要意义。为提高预测模型的准确性和适用性,基于肌肉协调理论,采用特征提取和主成分分析提取肌肉激活度,提出遗传算法(GA)优化的支持向量回归算法(Support Vector Regression, SVR)构建肌肉激活度和膝关节角度之间的映射模型,并对健康受试者和膝关节损伤患者在不同运动状态下的 sEMG 进行膝关节角度预测。GA-SVR 算法预测结果的均方根误差分别为 1.94° 和 2.44° , 远优于 BP 神经网络的 18.21° 和 18.28° 。结果表明,GA-SVR 具有较高的预测精度和较强的通用性。

关键词 表面肌电信号 连续运动预测 特征提取 膝关节 肌肉激活度

中图分类号 TP3 TP242

文献标志码 A

DOI:10.3969/j.issn.1000-386x.2023.11.050

PREDICTION MODEL OF CONTINUOUS KNEE ANGLE BASED ON SEMG

Tang Xiaoya Chen Feng

(School of Electrical Engineering, Nantong University, Nantong 226019, Jiangsu, China)

Abstract The model of mapping between surface electromyography (sEMG) and joint motion is very important for the continuous motion control of rehabilitation robot. In order to improve the accuracy and universality of the prediction model, based on the muscle coordination theory, feature extraction and principal component analysis were used to extract muscle activation. The support vector regression (SVR) optimized by genetic algorithm (GA) was proposed to construct the mapping model between muscle activation and knee joint angle. And the model was used to predict the knee angle of healthy subjects and patients with knee joint injury under different motion conditions. The root mean square error of GA-SVR algorithm was 1.94° and 2.44° respectively, which was much better than that of BP neural network 18.21° and 18.28° respectively. The results show that GA-SVR has high prediction accuracy and strong universality.

Keywords sEMG Continuous motion prediction Feature extraction Knee joint Muscle activation

0 引 言

相对于人工训练方式,康复机器人更适合长时间简单重复的运动,其广泛应用可以极大地缓解治疗师的缺乏,减轻他们的体力负担,同时能够降低康复成本,保证康复训练的强度和效果。而且机器人可编程,能够根据患者的康复状况进行参数和训练项目的调节,使用灵活。传统的康复训练过程就是遵循康复机器人固有模式并在医师帮助下用户完成动作训练,缺少人机交互,导致康复机器人与受试者之间运动不协调,并且康复医师精力十分有限,许多患者无法接受更

好的治疗。因此,提高康复机器人与患者之间的交互能力,实现康复机器人与受试者运动高度匹配是康复机器人控制现在面临的关键难题。

表面肌电信号(sEMG)是人体表面肌肉收缩过程中产生的生物电信号,具有采集方式简单快捷和蕴含信息量大等特点,已被广泛应用于康复医疗领域。建立连续运动过程中肌电信号和关节角度的映射模型,可以准确判断患者运动意图,对于康复设备的运动控制具有重要意义,也是当前研究的关键点。目前国内关于连续运动估计已经有许多进展,Zhang 等^[1]引入自回归综合(ARI)模型对膝关节角度进行预测,构建了基于网络的康复系统。Liu 等^[2]利用基于肌肉协

同理论的非负矩阵分解,提取出表面肌电信号的激活系数,采用广义神经网络(GRNN)构建从激活系数到膝关节角度的激活模型映射,实现连续膝关节角度估计。丁其川等^[3]采用主成分分析算法提取肌肉激活度,通过拟合高阶多项式构建运动模型关系,得到了80%左右的精确度。王斐等^[4]采用长短时记忆网络(LSTM)训练分析肌电信号-下肢运动之间的映射关系,对髋、膝和踝三个关节进行连续运动估计,并利用主成分分析提高了算法的实时性。有关连续运动中的关节角度预测还有一些研究成果^[5-14],但是精度普遍不够高,并且都是基于健康受试者的表面肌电数据进行实验,模型的普适性仍待验证。

综上所述,针对下肢关节损伤的患者仍需要建立切实有效的预测模型,本文基于健康受试者和膝关节损伤患者行、站和坐三种运动状态下的表面肌电信号,通过特征提取和肌肉协同分析提取肌肉激活度,然后采用改进的GA-SVR算法建立连续运动过程中肌肉激活度与膝关节角度预测模型,通过对比实验验证本文方法的精确性和有效性。

1 表面肌电信号的连续运动估计

本研究主要包括离线训练和运动预测两部分。在离线训练之前,通过开展大量的人体运动实验,采集所需肌电和运动数据,进行相应的信号处理与特征提取。在离线训练阶段,采用必要的机器学习方法对肌电和运动映射关系进行训练,获得合适的运动预测模型。在运动预测部分,输入新的肌电特征值至已训练的运动预测模型,从而获得相应的关节角度预测值。

1.1 表面肌电信号采集和活跃强度的计算

选取22名年龄在18岁以上的男性对象(包括11名健康男性和11名膝关节损伤的男性)参与信号采集。被试者分别进行匀速步行、站立及坐姿状态下膝关节的抬起和放下动作3种运动,采集3种运动状态下的表面肌电信号及同步信号膝关节角度数据,选择这三种运动是因为它们对于人们日常生活至关重要。实验数据采集设备使用DataLOG MWX8动态数据采集仪。数据的采样频率为1 000 Hz,分辨率为14位,肌电信号采集过程中分别选择健康被试者的左肢和膝关节损伤患者的患肢作为正常组和膝关节病理组。选择四个位置进行肌电信号的采集,采集位置如图1所示,按标号顺序分别为股内侧肌(VM)、半腱肌(St)、股二头肌(Bf)和股直肌(RF)。膝关节角度数据始终在膝关节外侧进行采集。




图1 sEMG传感器分布

肌电信号的处理过程主要分为滤波和特征提取两部分。滤波时采用五阶巴特沃斯滤波器对信号进行带通滤波,通带频率为20~300 Hz,阻带频率为4~400 Hz,然后去除50 Hz工频干扰。目前,肌电信号的特征提取主要分为时域和频域两个方面,时域特征具有较好的实时性,常被用于实时分析肌肉状态,且为降低计算复杂度,本实验采用时间窗分割的方法对每个通道的肌电信号进行时域特征提取,如图2所示。所采用的时域特征包括绝对平均值(MAV)、均方根值(RMS)、方差(VAR)、过零点数(ZC)和威尔逊幅值(WL),其计算公式分别如表1所示,其中: x_i 是单通道肌电信号序列, $i=1,2,\dots,N$; N 表示该通道肌电信号序列长度; N_t 表示时间窗长度。设置时间窗长度 $N_t=100$,依照上述步骤对一健康受试者的股直肌在步行过程中的信号做处理,其肌电信号的时域特征如图3所示。




图2 肌电信号时间窗分割方法

表1 时域特征计算方法

时域特征	描述	数学表达式
绝对平均值(MAV)	绝对值的平均值	$M_{AV} = \frac{1}{N} \sum_{i=1}^{N_t} x_i $
均方根值(RMS)	信号能量的一种量测	$R_{MS} = \sqrt{\frac{1}{N} \sum_{i=1}^{N_t} x_i^2}$
方差(VAR)	衡量信号波动大小的量	$V_{AR} = \frac{1}{N} \sum_{i=1}^{N_t} (x_i - \bar{x})^2$
过零点数(ZC)	一段时间内信号变化过程穿过x轴的次数	$Z_C = \sum_{i=1}^{N_t-1} \text{sgn}(-x_i x_{i+1}),$ $\text{sgn}(x) = \begin{cases} 1 & x > 0 \\ 0 & x \leq 0 \end{cases}$

续表 1

时域特征	描述	数学表达式
威尔逊幅值 (WL)	信号变化幅值累加之和	$W_L = \sum_{i=1}^{N_t-1} x_{i+1} - x_i $




图 3 步行运动中股直肌信号的时域特征

1.2 肌肉激活度分析

人体所有动作的完成都需要多块肌肉协同配合,为了解释运动过程中多自由度的协调问题,提出肌肉协同假设模型。在肌肉协同假设模型中,肌肉协同元作为肢体动作的最小控制单位,被定义为一组肌肉相对激活程度的向量,用 $\mathbf{W} = [\mathbf{W}_1, \mathbf{W}_2, \dots, \mathbf{W}_K]$ 表示,激活系数作为中枢神经系统所产生的激励信号, $\mathbf{H}(t) = [h_1, h_2, \dots, h_K]^T$ 用表示。激活系数激励肌肉协同元,使肌肉状态发生变化 $\mathbf{V}(t) = [v_1, v_2, \dots, v_N]^T$,最终完成肢体动作。依照肌肉协同模型,肌肉活动状态可表示为肌肉协同元和激活系数的线性组合:

$$\mathbf{V}_{N \times T} = \mathbf{W}_{N \times K} \times \mathbf{H}_{K \times T} \quad (1)$$

式中: N 为肌肉通道数; T 是信号样本点数; K 是肌肉协同元个数。

从多通道表面肌电信号中提取肌肉协同元属于盲源分离的过程,目前肌肉协同元提取常用的盲源分离算法有非负矩阵分解(NMF)、主成分分析(PCA)、独立成分分析(ICA)和因子分析(FA)。PCA 是应用最为广泛的特征提取方法,它能够在提取信号特征的同时降低变量维数,在上述对原始信号进行时域特征提取的过程中,一个通道的肌电信号被扩展成五维数据,具有较多冗余信息,采用 PCA 可以提取出最主要的特征分量,提高实时性。

假设 $S = \{s_m\}$ 是一个时域特征样本集, s_m 是 q 维向量,取任意两维向量 s_{i1} 和 s_{ij} ,令 $\mathbf{X} = s_{i1}, \mathbf{Y} = s_{ij}$,计算其协方差,计算公式如下:

$$\text{Cov}(\mathbf{X}, \mathbf{Y}) = \frac{\sum_{i=1}^n (\mathbf{X}_i - \bar{\mathbf{X}})(\mathbf{Y}_i - \bar{\mathbf{Y}})}{n - 1} \quad (2)$$

构建协方差矩阵:

$$\mathbf{C}_{ov} = \begin{pmatrix} \text{cov}(s_{k1}, s_{k1}) & \text{cov}(s_{k1}, s_{k2}) & \cdots & \text{cov}(s_{k1}, s_{kq}) \\ \text{cov}(s_{k2}, s_{k1}) & \text{cov}(s_{k2}, s_{k2}) & \cdots & \text{cov}(s_{k2}, s_{kq}) \\ \vdots & \vdots & \ddots & \vdots \\ \text{cov}(s_{kq}, s_{k1}) & \text{cov}(s_{kq}, s_{k2}) & \cdots & \text{cov}(s_{kq}, s_{kq}) \end{pmatrix} \quad (3)$$

由式(3)可知, $\mathbf{C}_{ov}$ 是一个 $q \times q$ 维的对称矩阵,假设 $\mathbf{C}_{ov}$ 的 q 个特征向量为 $\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_q$,令 $\mathbf{E} = (\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_q)$,则有:

$$\mathbf{E}^T \mathbf{C} \mathbf{E} = \mathbf{\Delta} = \begin{pmatrix} \lambda_1 & & & \\ & \lambda_2 & & \\ & & \ddots & \\ & & & \lambda_q \end{pmatrix} \quad (4)$$

式中: $\mathbf{\Delta}$ 为特征值矩阵,其对角元素为 $\mathbf{C}_{ov}$ 的特征值。

将 $\lambda_1, \lambda_2, \dots, \lambda_q$ 从小到大排列,重组特征值矩阵,记为 $\mathbf{\Delta}'$,并按照特征值顺序重组特征向量矩阵 $\mathbf{E}'$,主成分选择公式为:

$$\frac{\sum_{i=1}^n \Delta'_{ii}}{\sum_{i=1}^q \Delta_{ii}} \geq \rho \quad (5)$$

式中: n 是待求的主成分数量; ρ 是累计贡献率。通过所需精确度选择 $\mathbf{E}'$ 的前 n 个向量组成变换矩阵 $\mathbf{T}$, $\mathbf{S}$ 右乘变换矩阵 $\mathbf{T}$ 将获得 PCA 提取的主要特征分量。

令 $\rho = 0.99$,即从结果中提取累计贡献率达到 99% 的主成分,以一健康受试者步行过程中的时域特征信号为例,筛选后有 8 个主成分,其相应特征值如表 2 所示。

表 2 主成分累计贡献率

主成分	特征值	贡献率	累计贡献率
1	45.242	0.600	0.600
2	14.949	0.195	0.784
3	5.273	0.069	0.853
4	3.875	0.051	0.903
5	2.208	0.029	0.932
6	1.974	0.028	0.958
7	1.741	0.023	0.981
8	1.463	0.019	1.000

1.3 基于 GA_SVR 的关节角度预测模型

支持向量回归(SVR)是一种基于统计学习理论的

学习方法。其基本思想是找到一个回归平面,让一个集合的所有数据到该平面的距离最近。即对一个数据集 $\{(x_i, y_i), i=1, 2, \dots, n\}$, 其中 $x_i \in \mathbf{R}^d$ 和 $y_i \in \mathbf{R}^d$ 分别为输入向量和输出向量,通过非线性映射将输入变量映射到高维空间,并构建回归模型,如式(6)所示,找到向量 w 和系数 b 使 $f(x)$ 与 y 尽可能接近。

$$f(x) = w\varphi(x) + b \quad (6)$$

假设 ε 是 $f(x)$ 与 y 的最大偏差值,则 SVR 问题可转化为:

$$J = \frac{1}{2} \|w\|^2 + c \sum_{i=1}^n \varsigma_{\varepsilon}(f(x_i) - y_i) \quad (7)$$

式中: c 为惩罚因子; ς_{ε} 为不敏感损失函数。 ς_{ε} 如式(8)所示。

$$\varsigma_{\varepsilon}(z) = \begin{cases} 0 & |z| \leq \varepsilon \\ |z| - \varepsilon & |z| > \varepsilon \end{cases} \quad (8)$$

引入松弛变量 $\hat{\xi}_i, \xi_i$:

$$\begin{aligned} -(\varepsilon + \hat{\xi}_i) &\leq f(x_i) - y_i \leq \varepsilon + \xi_i \\ \hat{\xi}_i, \xi_i &\geq 0, i=1, 2, \dots, n \end{aligned} \quad (9)$$

式(7)可变为:

$$\min \frac{1}{2} \|w\|^2 + c \sum_{i=1}^n (\xi_i + \hat{\xi}_i) \quad (10)$$

引入拉格朗日乘子 α 和 $\hat{\alpha}$,可转化为对偶问题:

$$\begin{aligned} \max & \left(\sum_{i=1}^n y_i (\hat{\alpha}_i - \alpha_i) - \varepsilon (\hat{\alpha}_i + \alpha_i) - \right. \\ & \left. \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n (\hat{\alpha}_i - \alpha_i) (\hat{\alpha}_j - \alpha_j) K(x_i, x_j) \right) \quad (11) \\ \text{s. t. } & \sum_{i=1}^n (\hat{\alpha}_i - \alpha_i) = 0, \quad 0 \leq \hat{\alpha}_i, \alpha_i \leq c \end{aligned}$$

进而可得到回归模型:

$$f(x) = \sum_{i=1}^n (\hat{\alpha}_i - \alpha_i) K(x_i, x) + b \quad (12)$$

式中: $K(x_i, x_j) = \exp[-\gamma \|x_i - x_j\|^2]$ 是径向基核函数。

SVR 预测模型有两个非常重要的参数 c 与 g 。其中 c 是惩罚系数,即对误差的宽容度。 c 过大,会导致过拟合状态发生; c 过小,会导致欠拟合状态发生。无论 c 过大还是过小,都会使模型的泛化能力变差。 g 是核函数参数,即 γ 。它隐含地决定了数据映射到新的特征空间后的分布, g 越大,支持向量越少, g 值越小,支持向量越多。支持向量的个数影响训练与预测的速度。 GA 是模拟生物进化的自然选择和遗传学机制而成,是一种高效、并行和全局搜索的自适应概率优化算法,目前已被人们广泛地应用于组合优化、机器学习、信号处理、自适应控制和人工生命等领域。利用 GA 对 SVR 的两个参数进行寻优,可以提高预测精度。

参数 c 与 g 的寻优过程如下:

1) GA 参数初始化和种群初始化。设置 GA 参数包括最大迭代次数、种群规模、参数变化范围、交叉概率等,并采用实数编码方式对随机一组参数 c 与 g 进行编码,构造初始种群。

2) 适应度函数。根据个体得到相应参数之后,将其代入 SVR,令 SVR 预测结果的误差绝对值作为适应度函数值:

$$F_i = \frac{1}{n} \sum_{i=1}^n |\theta_i - \hat{\theta}_i| \quad (13)$$

3) 遗传操作。选择、交叉、变异是遗传算法的基本操作。选择操作采用基于适应度比例的轮盘赌法,可以按照适应度大小择优选择个体;交叉操作采用单点交叉法,即在个体编码串中随机设置一个交叉点,在该点交换两个个体的部分染色体;变异操作方法如式(14)所示。

$$a_{ij} = \begin{cases} a_{ij} + (a_{ij} - a_{\min}) \cdot f(g) & r_1 > 0.5 \\ a_{ij} + (a_{\max} - a_{ij}) \cdot f(g) & r_1 \leq 0.5 \end{cases} \quad (14)$$

$$f(g) = r_2 \left(1 - \frac{g}{G_{\max}}\right)^2 \quad (15)$$

式中: $a_{\max}, a_{\min}$ 分别为 a_{ij} 的最大值、最小值; g 为当前迭代次数; $G_{\max}$ 为最大迭代次数; r_1, r_2 为 $[0, 1]$ 间的随机数。

GA-SVR 预测模型的流程如图 4 所示。




图 4 GA-SVR 预测模型流程

2 实验与结果分析

本文的目的是对不同健康状态的受试者在三种运动状态下的肌电信号进行膝关节角度预测,对 22 名被

试者的数据进行对比实验,以验证方法的有效性。首先从 22 名被试者的 4 块肌肉的原始肌电数据中提取每块肌肉电信号的 5 个特征值,得到 20 维肌电特征数据,然后为方便后续建立预测模型,统一提取 20 维肌电信号的前 8 个主成分,并将肌电数据和膝关节数据分为训练集和测试集,最后用 GA-SVR 和 BP 神经网络对训练集数据进行训练。其中 GA-SVR 预测算法的 GA 参数为:最大迭代次数为 200,种群规模为 20,交叉概率为 0.7,变异概率为 0.2,得到最优的 SVR 参数为 $c = 16$ 、 $g = 0.125$ 。BP 神经网络采用双隐含层结构,隐含层神经元个数均为 20,隐含层和输入输出层的节点转移函数均为 tansig 函数。并以均方根误差和相关系数作为预测方法的评估准则:

$$M_{SE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (\theta_i - \hat{\theta}_i)^2}$$
 (16)

$$R = \frac{\text{Cov}(\theta, \hat{\theta})}{\sqrt{D(\theta)} \sqrt{D(\hat{\theta})}}$$
 (17)

式中: M_{SE} 为均方根误差; R 为相关系数; θ_i 为膝关节真实角度; $\hat{\theta}_i$ 为膝关节预测角度; $\text{Cov}(\theta, \hat{\theta})$ 是 θ 和 $\hat{\theta}$ 协方差; $\sqrt{D(\theta)}$ 和 $\sqrt{D(\hat{\theta})}$ 分别为 θ 和 $\hat{\theta}$ 的方差。

随机选取一名健康受试者和一名膝关节损伤患者的预测结果进行对比分析,如图 5 所示,从上到下依次为站、坐和行三种运动状态下的连续膝关节角度预测结果。对两种算法的预测结果进行误差分析和相关系数分析,误差及相关系数数据记录在表 3 中。可以看出,对于健康受试者,GA-SVR 三种运动状态下预测结果的均方根误差分别为 0.91、2.68 和 2.23,BP 神经网络预测结果的均方根误差分别为 13.25、23.14 和 18.24;对于膝关节损伤的受试者 GA-SVR 预测结果的均方根误差分别为 1.29、2.93 和 3.11,BP 神经网络预测结果的均方根误差分别为 20.62、25.24 和 8.98。同时 GA-SVR 预测结果的相关系数平均为 98%,BP 预测结果的相关系数低至 59%。显然 GA-SVR 的预测结果远优于 BP 神经网络,更加贴合实际膝关节运动角度,并且对于膝关节损伤的患者 GA-SVR 同样表现优异。





图 5 膝关节角度预测结果和原始数据对比

表 3 本文模型和 BP 神经网络模型的性能对比

受试者		健康		膝关节损伤	
		$M_{SE}/(^{\circ})$	R	$M_{SE}/(^{\circ})$	R
GA-SVR	步行	1.21	0.98	1.29	0.97
	站立	2.68	0.98	2.93	0.96
	坐姿	2.23	0.97	3.11	0.97

续表 3

受试者		健康		膝关节损伤	
		$M_{SE}/(^{\circ})$	R	$M_{SE}/(^{\circ})$	R
平均值		2.04	0.98	2.44	0.97
BP	步行	13.25	0.76	20.62	0.59
	站立	23.14	0.88	25.24	0.75
	坐姿	18.24	0.84	8.98	0.84
平均值		18.21	0.83	18.28	0.73

3 结 语

本文以康复机器人为研究背景,提出康复机器人领域还存在人机运动不协调问题,进而为提高人机交互能力,提出基于表面肌电信号的连续膝关节运动角度预测模型,采用信号特征提取和肌肉协同理论提取肌肉激活度,并通过遗传算法改进 SVR 的惩罚系数和核函数参数,通过健康受试者和膝关节损伤患者的关节预测实验,验证了 GA-SVR 模型的有效性和适用性。同时与 BP 神经网络进行对比实验,结果表明受试者在站、立和行三种运动状态下 GA-SVR 的预测精度远高于 BP 神经网络,具有更高的相关系数,更加贴合人体膝关节运动角度。研究表明了肌电信号预测关节角度对于健康受试者和膝关节损伤患者的可行性,为康复机器人同步运动控制提出了更好的方法。后续将进一步研究康复状态评估实现医师的远程诊疗。

参 考 文 献

- [1] Zhang W, Tomizuka M, Bae J. Time series prediction of knee joint movement and its application to a network-based rehabilitation system [C]//2014 American Control Conference, 2014.
 - [2] Liu Q, Ma L, Ai Q, et al. Knee joint angle prediction based on muscle synergy theory and generalized regression neural network [C]//2018 IEEE/ASME International Conference on Advanced Intelligent Mechatronics(AIM), 2018.
 - [3] 丁其川,赵新刚,韩建达. 基于肌电信号的上肢多关节连续运动估计[J]. 机器人, 2014, 36(4): 469-476.
 - [4] 王斐,魏晓童,秦皞. 基于 sEMG 和 LSTM 的下肢连续运动估计[J]. 东北大学学报(自然科学版), 2020, 41(3): 305-310, 342.
 - [5] 刘峻豪. 基于表面肌电信号的下肢步态及姿势识别算法的研究[D]. 成都: 西华大学, 2020.
 - [6] 隋修武,石峰. 基于改进 MPSO-SVM 算法的下肢连续运动预测模型[J]. 天津工业大学学报, 2019, 38(6): 69-75.
 - [7] 金啟媛. 外骨骼型下肢康复机器人结构设计与控制方法研究[D]. 武汉: 武汉理工大学, 2019.
 - [8] 王昕. 面向下肢康复机器人的运动意图识别技术研究[D]. 杭州: 浙江大学, 2019.
 - [9] 桂奇政,孟明,马玉良,等. 基于肌肉协同激活模型的上肢关节运动连续估计[J]. 仪器仪表学报, 2016, 37(6): 1405-1412.
 - [10] 尹诗明. 踝关节康复机器人概念化设计及其控制策略研究[D]. 哈尔滨: 哈尔滨工业大学, 2016.
 - [11] 黄新宇. 基于人体步态和表面肌电信号的康复评估方法研究[D]. 武汉: 武汉理工大学, 2016.
 - [12] Mokdad A, Debbal S M E A, Meziani F. Diagnosis of amyotrophic lateral sclerosis (ALS) disorders based on electromyogram(EMG) signal analysis and feature selection[J]. Polish Journal of Medical Physics and Engineering, 2020, 26(3): 155-160.
 - [13] Stapornchaisit S, Kim Y, Takagi A, et al. Finger angle estimation from array EMG system using linear regression model with independent component analysis[J]. Frontiers in Neurobotics, 2019, 13: 75.
 - [14] Moissenet F, Bélaïse C, Piche E, et al. An optimization method tracking EMG, ground reactions forces, and marker trajectories for Musculo-Tendon forces estimation in equinus gait[J]. Frontiers in Neurobotics, 2019, 13: 48.
- ~~~~~
- (上接第 334 页)
- [10] Meng C, Das A K, Ramakrishnan A, et al. Precoding-based network alignment for three unicast sessions [J]. IEEE Transactions on Information Theory, 2015, 61(1): 426-451.
 - [11] 杨天西. 防窃听的安全网络编码的研究[D]. 成都: 西南交通大学, 2014.
 - [12] Cai N, Yeung R W. Secure network coding on a wiretap network[J]. IEEE Transactions on Information Theory, 2011, 57(1): 424-435.
 - [13] Bhattad K, Narayanan K. Weakly secure network coding [J]. Computer Science, 2005.
 - [14] 徐光宪,王栋. 基于混沌加密对抗窃听的安全网络编码方案[J]. 计算机应用, 2019, 39(5): 1374-1377.
 - [15] Guo Q, Luo M X, Li L X, et al. Secure network coding against wiretapping and Byzantine attacks [J]. EURASIP Journal on Wireless Communications and Networking, 2010, 2010: 216524.
 - [16] Liu G J, Liu B Y, Liu X M, et al. Low-complexity secure network coding against wiretapping using intra/inter-generation coding[J]. China Communications, 2015, 12(6): 116-125.
 - [17] Vilela J P, Lima L, Barros J. Lightweight security for network coding [C]//2008 IEEE International Conference on Communications. IEEE, 2008: 1750-1754.