

基于表面肌电信号的上肢康复动作识别

顾玉平¹, 李宪华^{2*}, 张康¹, 罗耀²

(1. 安徽理工大学 人工智能学院, 安徽 淮南 232001; 2. 安徽理工大学 机电工程学院, 安徽 淮南 232001)

摘要: 选取上肢肱桡肌、尺侧弯曲肌、肱肌、肱二头肌、三角肌作为采集对象, 使用干电极片以及数据采集卡采集表面肌电信号(sEMG)。将采集到的表面肌电信号进行预处理, 提取时域特征、频域特征以及信息熵特征, 将提取的特征用于卷积神经网络模型的训练, 再抽取特征值部分样本作为验证集合进行交叉验证。实验结果表明, 融合信息熵作为特征样本训练准确率达91%, 明显高于单一特征样本以及融合时频域特征样本。

关键词: 表面肌电信号; 模式识别; 康复运动; 卷积神经网络

DOI:10.3969/j.issn.1674-5043.2024.03.009

中图分类号: TP391.4

文献标识码: A

文章编号: 1674-5043(2024)03-0056-06

上肢康复是帮助脑卒中等失去行为能力的患者恢复手臂和手部功能的重要过程, 传统的康复方法往往依赖于专业医护人员的直接干预。近年来, 基于表面肌电信号(surface electromyogram signal, sEMG)的上肢康复动作识别技术引起了广泛的关注和研究。通过使用sEMG技术可以实现非侵入、实时、高灵敏度和多样性的肌肉电信号获取, 为上肢康复提供新的途径^[1-4]。

国内外研究者们通过开发高效的动作识别算法、设计精密的肌电传感器、结合虚拟现实技术, 致力于解决康复过程中的关键问题, 旨在实现对康复动作的实时监测和反馈, 帮助康复患者改善肢体功能, 提高生活质量。国外研究侧重于深度学习算法和实时反馈系统的开发, 以及将肌电信号与虚拟现实相结合, 提供更具交互性和趣味性的康复训练体验。国内研究着眼于低成本高精度的传感器技术和康复机器人的研发, 期望将先进技术应用于临床实践, 为康复医学带来新的突破和发展^[5-8]。

针对上肢康复运动模式识别进行研究, 提取指定上肢运动动作时的表面肌电信号, 设计6种不同的上肢运动姿势, 采集表面肌电信号, 通过模式识别出不同的动作姿态。本文提出了一种基于表面肌电信号识别上肢康复动作模式识别方法, 通过卷积神经网络融合表面肌电信号的时频域特征以及信息熵特征信号作为输入, 以6种不同的上肢姿势作为输入, 建立表面肌电信号和上肢运动姿势的预测模型。本研究有助于提高上肢康复机器人模式识别的准确性以及控制精度, 提高上肢康复机器人的适应能力。

1 信号采集

表面肌电信号是皮肤表面肌肉活动产生的电信号。采集表面肌电信号的原理是利用肌肉收缩时产生的电位差, 通过电极捕捉并放大这些信号。sEMG技术能够准确捕捉肌肉活动, 实时识别运动意图, 并且可穿戴、成本较低, 可以利用表面肌电信号对人体的运动意图进行识别以完成康复训练。

本文主要对上肢的6个不同动作进行采集, 针对不同的姿态确定活跃肌肉进行表面肌电信号的采集。实验对象为10位无肌肉、骨骼及其他运动系疾病的健康成年人, 设计6个不同动作, 实验对象每个动作重复10次, 每次间隔5s。表面肌电信号采集设备的结构如图1所示, 采用高效并联设计, 利用数据采集卡同时连接多个DFRobot Gravity肌电传感器, 形成一个多通道的肌电采集系统。本文选用5个肌电传感器进行并联, 能够同时捕捉5块不同肌肉的信号。在使用过程中, 干电极片被固定在肌肉表面, 与数据采

收稿日期: 2024-04-16

作者简介: 顾玉平(1999—), 女, 安徽淮南人, 在读硕士研究生, 主要从事表面肌电信号方面的研究. E-mail: 2022201841@aust.edu.cn

通讯作者: 李宪华(1980—), 男, 山东济南人, 博士后, 教授, 主要从事机器人技术与智能材料方面的研究. E-mail: xianhuali@qq.com

基金项目: 安徽省重点研究与开发计划项目(2022i01020015)。

集卡相连，确保稳定的信号传输。传感器将采集到的信号通过数据采集卡传输到计算机中，并以电压随时间变化的文本数据形式保存，提高了信号采集的效率，保证了采集数据的准确性和可靠性。采集设备的工作电压为 3 V，采样频率为 3 000 Hz，能够以 3 000 次/s 的速率获取肌肉表面的信号变化情况，捕捉到肌肉运动过程中微妙的变化，为后续的信号分析和处理提供高质量的数据。




图 1 表面肌电信号采集设备

人体上肢运动主要用到的肌肉有胸大肌、肱二头肌、三角肌、肱桡肌等。选择肱桡肌、尺侧弯曲肌、肱肌、肱二头肌以及三角肌作为采集对象，设计向前伸展、侧向伸展、屈肘、扶肩、抬肘和向上伸展 6 个动作如图 2 所示，采集对象如图 3 所示。




图 2 6 种不同上肢动作




图 3 表面肌电信号的采集对象

2 预处理

采集设备采集到的原始表面肌电信号既包含了运动姿态信息,也包含了工频干扰,心电或者其他呼吸相关的干扰等外界噪声^[9],需要对采集到的信号进行滤波处理。本文采用巴特沃兹滤波器对采集到的信号进行低通滤波,抑制超过 500 Hz 的信号,再采用陷波器去除 50 Hz 的交流电路工频干扰。去噪前后的肌电信号如图 4 和图 5 所示。




图 4 原始肌电信号




图 5 去噪后肌电信号

3 特征提取

对 6 个不同动作提取信号的时域特征、频域特征、信息熵作为表面肌电信号识别的特征指标。

3.1 时域特征

绝对值均值 (MAV)。绝对值均值是在一段时间内 sEMG 信号绝对值的平均值,反映了肌肉活动的整体水平,即肌肉在一段时间内的平均激活程度。

$$R_{\text{MAV}} = \frac{1}{N} \sum_{i=1}^N |x_i| \quad (1)$$

均方根 (RMS)。均方根表示信号的平均幅度的大小,可以提供关于肌肉活动强度的信息。

$$R_{\text{RMS}} = \sqrt{\frac{\sum_{i=1}^N x_i^2}{N}} \quad (2)$$

方差 (VAR)。方差代表 sEMG 信号的波动性,可以用来评估肌肉收缩的不规则性或运动控制的精确度,在运动控制方面具有重要的作用。

$$R_{\text{VAR}} = \frac{1}{N-1} \sum_{i=1}^N x_i^2 \quad (3)$$

式中: R_{MAV} 为绝对值均值 (MAV), x_i 为表面肌电信号, N 为信号长度, R_{RMS} 为均方根 (RMS), R_{VAR} 为方差 (VAR)。

3.2 频域特征

中值频率 (MF)。在表面肌电信号中,中值频率代表信号频谱中频率的中值,通常指频谱的平均频率。

$$R_{\text{MF}} = \frac{1}{2} \int_0^{\infty} P(f) df \quad (4)$$

平均功率频率 (MPF)。平均功率频率代表信号频谱中功率加权的频率平均值,提供了关于 sEMG 信号平均分布的信息,可以用于确定信号中频率分量的主要集中区域。

$$R_{\text{MPF}} = \frac{\int_0^{\infty} f \cdot P(f) df}{\int_0^{\infty} P(f) df} \quad (5)$$

式中： R_{MF} 表示中值频率（MF）， $P(f)$ 表示肌电信号功率谱密度函数， f 表示肌电信号的频率， R_{MPF} 表示平均功率频率（MPF）。

6 种不同动作 sEMG 的时域特征值和频域特征值分别如表 1 和表 2 所示。

表 1 sEMG 的时域特征值

时域特征	通道	向前伸展	侧向伸展	屈肘	扶肩	抬肘	向上伸展
MAV	1	18.29	17.08	8.23	9.45	0.69	0.84
	2	6.24	8.04	4.65	18.79	9.13	2.09
	3	0.08	3.56	19.9	2.05	1.66	0.08
	4	1.41	6.32	17.43	0.31	3.01	1.95
	5	3.2	3.41	25.96	9.92	7.41	4.21
RMS	1	0.66	0.59	0.54	0.48	0.56	0.84
	2	0.23	0.17	0.33	0.45	0.32	0.78
	3	0.05	0.06	0.69	0.89	0.57	0.82
	4	0.05	0.07	0.33	0.38	0.23	0.57
	5	0.57	0.55	0.85	0.64	0.52	4.24
VAR	1	4.44	3.53	3.35	2.79	3.18	0.21
	2	0.56	0.29	1.17	2.18	1.06	0.11
	3	0.03	0.03	4.78	8.18	3.46	0.07
	4	0.03	0.06	1.21	1.84	0.68	0.03
	5	3.24	2.99	7.18	4.19	2.74	1.89

表 2 sEMG 的频域特征值

频域特征	通道	向前伸展	侧向伸展	屈肘	扶肩	抬肘	向上伸展
MF	1	17.28	19.66	35.14	33.81	29.67	22.91
	2	154.3	108.61	18.6	27.62	26.5	135.44
	3	127.35	30.03	12.94	17.56	19.65	138.26
	4	166.79	120.5	110.32	168.34	133.23	146.35
	5	23.57	17.02	15.69	16.55	19.38	25.4
MPF	1	156.35	108.16	86.13	88.31	103.49	138.2
	2	95.36	94.62	103.57	89.47	96.31	97.52
	3	80.67	99.7	81.9	97.64	85.64	89.63
	4	237.6	133.23	134.04	157.36	157.61	214.6
	5	85.15	103.4	80.1	95.34	98.33	94.2

3.3 信息熵

信息熵是信息理论中的一种度量，可以提供关于肌肉活动的动力学特性和模式信息，用于衡量信号的不确定性和复杂性^[10]。为了计算信息熵，将 sEMG 信号划分成长度 N 的不重叠窗口，每个窗口内包含 M 个采样点。对每个窗口计算概率密度函数，并应用香农熵

$$H(X) = - \sum_{i=1}^n P(x_i) \cdot \log_2 P(x_i) \tag{6}$$

式中： $P(x_i)$ 为 sEMG 信号在窗口中第 i 个采样点的概率。

在每个窗口内，计算得到一个熵值作为时序特征。这些时序特征形成了一个熵序列，代表了 sEMG 信号在不同时间窗口内的时空动态变化。

4 分类识别

4.1 卷积神经网络模型

卷积神经网络(Convolutional Neural Network, CNN)是一种深度学习模型,专门用于处理具有类似网格结构的数据^[11]。CNN通过层层堆叠的卷积操作和非线性激活函数来逐渐提取输入数据的特征,并在最后的全连接层中进行分类或回归。本研究采用卷积神经网络作为特征识别和分类的模型。

本文设计了一个卷积神经网络,包括卷积层、池化层和全连接层。卷积层用于提取 sEMG 信息的时频特征,池化层用于降维和保留主要信息,全连接层用于学习特征之间的复杂关系。将基于信号熵和时频域特征取得到的特征矩阵作为 CNN 的输入,在训练前对数据集进行适当的数据划分,保证模型训练和测试的独立性。

4.2 损失函数和优化器的选择

在表面肌电信号的分类任务中,通常使用交叉熵损失函数。交叉熵损失函数在多类别分类问题中表现良好,能够度量模型输出与真实标签之间的差异。对于多类别问题,交叉熵损失函数

$$C_r = - \sum_{i=1}^C y_i \lg(\hat{y}_i) \quad (7)$$

式中: C 表示类别数; y_i 是真实标签的独热编码; $\hat{y}_i$ 是模型输出的概率分布。

为了使损失函数最小,选择 Adam 优化器。Adam 是一种自适应学习率的优化算法,结合了动量法和 RMSProp 算法的思想,对于不同特征和参数具有较好的适应性。

Adam 优化器的规则:

$$m_i = \beta_1 m_{i-1} + (1 - \beta_1) \nabla_{\theta} J(\theta) \quad (8)$$

$$v_i = \beta_2 v_{i-1} + (1 - \beta_2) (\nabla_{\theta} J(\theta))^2 \quad (9)$$

$$\theta_i = \theta_{i-1} - \alpha \frac{m_i}{\sqrt{v_i} + \epsilon} \quad (10)$$

式中: θ 为模型参数; $J(\theta)$ 为损失函数; α 为学习率; β_1 和 β_2 为衰减因子,是为了数值稳定而添加的小常数。

4.3 结果分析



采集的肱桡肌、尺侧弯曲肌、肱肌、肱二头肌、三角肌的表面肌电信号用于上肢康复动作的姿态识别,结果如表 3 所示。采用单一特征时,绝对值均值的准确率为 65.35%,均方根的准确率为 77.6%,方差的准确率为 76.54%,中值频率准确率为 62.35%,平均功率谱准确率为 68.37%;同时采用时频域特征的准确率为 85.4%;加入信息熵作为特征的准确率为 91.2%。不同肌肉群的特征虽然存在差异,但是伸展动作之间的特征存在相似重叠部分,导致单一特征的准确率不高,结合时频域特征能够提高一定的准确率,在时频域特征融合的基础上融合代表信息复杂程度的信息熵作为补充特征能够显著提高动作识别的准确率,融合信息熵后康复动作的准确率为 91.2%,如图 6 所示。融合信息熵特征的混淆矩阵如图 7 所示,从图 7 可以看出动作 3 相对其他几个动作预测准确率相对较低。

5 结 语

针对表面肌电信号对上肢康复动作姿态识别进行分析,设计 6 种不同姿势,利用 sEMG 信号的特征对不同姿态进行分类识别预测。集合卷积神经网络模型将 sEMG 与不同姿态对应,通过 sEMG 对康复动作进行识别预测。融合信息熵特征对上肢康复姿态识别的准确率有显著提高。

表 3 sEMG 识别准确率

项目	MAV	RMS	VAR	MF	MPF	时频域	融合信息熵
准确率/%	65.35	77.6	76.54	62.35	68.37	85.4	91.2



参考文献：

[1] 李沿宏,江茜,邹可,等.融合注意力机制的多流卷积肌电手势识别网络[J].计算机应用研究,2021,38(11):3258-3263.

[2] 姜荣荣,叶正茂,陈艳,等.上肢康复机器人对偏瘫上肢运动功能和日常活动能力的影响[J].中国康复,2020,35(10):517-521.

[3] MUNOZ-NOVOA M,KRISTOFFERSEN M B,SUNNERHAGEN K S,et al.Upper Limb Stroke Rehabilitation Using Surface Electromyography: A Systematic Review and Meta-Analysis[J].Frontiers in Human Neuroscience,2022,16(5):1356-1369.

[4] XU H,XIONG A B.Advances and Disturbances in sEMG-Based Intentions and Movements Recognition: A Review[J].Iee Sensors Journal,2021,21(12):13019-13028.

[5] SHEN S,GU K,CHEN X R,et al.Gesture Recognition Through sEMG with Wearable Device Based on Deep Learning[J].Mobile Networks & Applications,2020,25(6):2447-2458.

[6] FENG Y F,YU L,DONG F Y,et al.Research on the method of identifying upper and lower limb coordinated movement intentions based on surface EMG signals[J].Frontiers in Bioengineering and Biotechnology,2024,11(9):1897-1912.

[7] BURNS A,ADELI H,BUFORD J A.Upper Limb Movement Classification via Electromyographic Signals and an Enhanced Probabilistic Network[J].Journal of Medical Systems,2020,44(10):297-309.

[8] 任丽晔,徐冬蕾.基于人体上肢表面肌电信号在运动过程中的研究[J].长春大学学报,2020,30(4):45-48.

[9] 张洋.基于表面肌电信号的下肢运动识别研究[D].武汉:江汉大学,2024:15-18.

[10] 高磊.信息熵和改进特征权重融合的 Adaboost-SSA-BP 步态识别方法[J].计算机时代,2023(12):96-100,104.

[11] 刘威,王从庆.基于 CNN 和 sEMG 的手势识别及康复手套控制[J].吉林大学学报(信息科学版),2020,38(4):419-427.

Upper Limb Rehabilitation Action Recognition Based on Surface EMG

GU Yuping¹, LI Xianhua^{2*}, ZHANG Kang¹, LUO Yao²

(1. School of Artificial Intelligence, Anhui University of Science and Technology, Huainan 232001, China;

2. School of Mechanical and Electrical Engineering, Anhui University of Science and Technology, Huainan 232001, China)

Abstract: In this paper, the brachioradialis muscle, ulnar flexor muscle, brachialis muscle, biceps brachialis muscle and deltoid muscle of upper limb were selected as the collection objects, and the surface EMG signal was collected by dry electrode and data acquisition card. The time domain features, frequency domain features and information entropy features are extracted after pre-processing the collected surface EMG signals, and the extracted features are used to train the convolutional neural network model. Then some samples of eigenvalues are selected as verification sets for cross-verification. The experimental results show that the training accuracy of fusion information entropy as a feature sample is as high as 91%, which is obviously higher than that of single feature sample and fusion time-frequency domain feature sample.

Keywords: sEMG; pattern recognition; rehabilitation exercise; CNN

(责任编辑:翟智卫)