

学校代码: 10270

学号: 212503020

上海师范大学

硕士专业学位论文

基于表面肌电信号的肌肉疲劳识别 系统设计

学 院: 信息与机电工程学院

专业学位类别: 电子信息

专 业 领 域: 电子信息

研 究 生 姓 名: 吉星照

指 导 教 师: 李传江

完 成 日 期: 2024 年 3 月

摘要

在竞技体育领域，运动员的训练强度是提升比赛成绩的关键因素。然而，未经控制的高强度训练可能导致肌肉疲劳和损伤。因此，运用科学技术手段监测运动员的肌肉疲劳状态具有重大意义。表面肌电（sEMG）信号来源于中枢神经系统对外界刺激作出反映时的电位变化，包含了丰富的肌肉状态信息，广泛应用于疲劳检测、姿态识别和假肢控制等领域，所以在评价肌肉疲劳方便备受关注。然而肌肉疲劳识别是一项复杂的模式识别任务，其挑战在于从肌肉活动中提取出对识别准确性影响最大的生理特征。针对常规肌肉疲劳识别方法准确率低，特征冗余的问题，本文使用了一种基于 ReliefF-NOSCA-AdakNN（RNA）的特征选择和分类算法，通过对表面肌电信号的采集、预处理、特征提取和筛选，建立了肌肉疲劳识别模型。最终通过软硬件设计，建立了一套肌肉疲劳识别系统。

本文主要研究工作如下：

（1）肌肉疲劳等级状态的划分。设计了基于个体疲劳主观感受的 sEMG 信号采集实验，考虑到信号特征与受试者体态和性别的相关性，收集了 10 名参与者在不同肌肉疲劳状态下的肱二头肌 sEMG 信号，以确保数据的多样性。随后，使用了监督学习方法对数据进行标签分类。

（2）提出一种基于 ReliefF-NOSCA-AdakNN(RNA)的表面肌电信号(sEMG)特征提取和分类算法。该算法结合了特征和类别之间的相关性分析和启发式搜索算法，并针对分类类别不平衡进行优化，实现了对高维特征的有效筛选和分类。本文设计了对比实验和消融实验验证了该算法的正确性和先进性。实验结果显示，算法的平均分类准确率达到 83.88%，并且在特征数量减少和分类精度等方面超越了传统单一算法。

（3）肌肉疲劳实时识别系统的研发。根据表面肌电信号特性，设计基于 STM32 和凝胶电极的表面肌电信号采集系统，并结合肌肉疲劳识别系统的需求和流程，开发了能够实时进行 sEMG 信号特征提取和分类的上位机软件系统。本研究通过实验验证了系统的有效性，其实用性在拳击运动场景中得到了验证。

本文完成的肌肉疲劳识别系统能够对训练中人员的肌肉疲劳状况进行分析预测，对康复医学、生物医学和运动科学等领域具有重要的现实意义和应用价值。

关键词：表面肌电信号；特征选择；肌肉疲劳；模式识别

Abstract

In the field of competitive sports, athletes' training intensity is a key factor in improving competition performance. However, uncontrolled high-intensity training can lead to muscle fatigue and damage. Therefore, it is of great significance to use scientific and technical means to monitor athletes' muscle fatigue status. Surface electromyography (sEMG) signals originate from potential changes when the central nervous system responds to external stimuli. It contains rich muscle state information and is widely used in fatigue detection, posture recognition, prosthetic control and other fields, so it is convenient for evaluating muscle fatigue. Much attention. However, muscle fatigue recognition is a complex pattern recognition task, and the challenge lies in extracting the physiological features from muscle activity that have the greatest impact on recognition accuracy. In order to solve the problems of low accuracy and redundant features of conventional muscle fatigue identification methods, this article uses a feature selection and classification algorithm based on ReliefF-NOSCA-AdakNN (RNA), which collects, preprocesses and features the surface electromyographic signals. After extraction and screening, a muscle fatigue identification model was established. Finally, through software and hardware design, a muscle fatigue identification system was established.

The main research work of this article is as follows:

(1) Classification of muscle fatigue levels. A sEMG signal collection experiment based on individual subjective feelings of fatigue was designed. Taking into account the correlation between signal characteristics and the subject's posture and gender, the biceps brachii sEMG signals of 10 participants under different muscle fatigue states were collected to ensure Data diversity. Subsequently, a supervised learning approach was used to label the data.

(2) Propose a surface electromyographic signal (sEMG) feature extraction and classification algorithm based on ReliefF-NOSCA-AdakNN (RNA). This algorithm combines correlation analysis and heuristic search algorithms between features and categories, and is optimized for classification category imbalance, achieving effective screening and classification of high-dimensional features. This paper designed comparative experiments and ablation experiments to verify the correctness and advancement of the algorithm. Experimental results show that the average classification accuracy of the algorithm reaches 83.88%, and surpasses the traditional single

algorithm in terms of feature number reduction and classification accuracy.

(3) Research and development of real-time identification system for muscle fatigue. According to the characteristics of surface electromyography signals, a surface electromyography signal acquisition system based on STM32 and gel electrodes was designed. Combined with the needs and processes of the muscle fatigue identification system, a host computer software system that can extract and classify sEMG signal features in real time was developed. This study verified the effectiveness of the system through experiments, and its practicality was verified in boxing sports scenarios.

The muscle fatigue identification system completed in this article can analyze and predict the muscle fatigue status of personnel during training, and has important practical significance and application value in the fields of rehabilitation medicine, biomedicine, and sports science.

Key Words: surface electromyography signal; feature selection; muscle fatigue; pattern recognition

目录

摘要.....	I
Abstract.....	II
目录.....	IV
第 1 章 绪论.....	1
1.1 研究背景及意义.....	1
1.2 国内外研究现状.....	1
1.2.1 肌肉疲劳识别的国内外研究现状.....	2
1.2.2 特征选择方法的国内外研究现状.....	4
1.3 本论文工作概述及章节安排.....	6
第 2 章 肌肉疲劳识别模型建立.....	9
2.1 表面肌电信号数据分割.....	9
2.2 表面肌电信号特征提取.....	10
2.2.1 特征计算.....	10
2.2.2 特征选择.....	12
2.3 基于 RNA 算法的肌肉疲劳识别模型建立.....	13
2.3.1 基于 ReliefF 算法的特征权重估计模型.....	13
2.3.2 基于 NOCSA 算法的特征筛选模型.....	14
2.3.3 基于 Ada-kNN 算法的分类器模型.....	16
2.4 RNA 算法评估实验.....	17
2.4.1 评价指标.....	18
2.4.2 ReliefF 实验结果分析.....	19
2.4.3 RNA 算法消融实验分析.....	20
2.4.4 特征选择算法对比实验.....	21
2.4.5 分类器对比实验.....	22
2.4.6 与其他肌肉疲劳识别算法对比.....	26
2.5 本章总结.....	27
第 3 章 肌肉疲劳识别系统设计.....	28
3.1 系统整体需求分析.....	28
3.2 系统整体方案设计.....	28
3.3 表面肌电信号采集平台设计.....	29
3.3.1 主控芯片选型和软件设计.....	29
3.3.2 多级放大电路芯片选型和电路设计.....	31

3.3.3 表面电极的选择	33
3.4 肌肉疲劳识别上位机分析平台设计	34
3.4.1 开发框架的选择	34
3.4.2 串口通信协议设计	34
3.4.3 波形显示模块设计	35
3.4.4 疲劳分析模块设计	36
3.4.5 用户数据库设计	37
3.4.6 软件界面设计	38
3.5 本章总结	40
第 4 章 肌肉疲劳识别实验与系统测试	41
4.1 表面肌电信号采集及分析	41
4.1.1 实验设备	41
4.1.2 方案设计	41
4.1.3 实验流程	43
4.1.4 特征分析	46
4.2 肌肉疲劳识别系统测试	47
4.2.1 肌肉疲劳识别功能测试	47
4.2.2 肌电信号存储功能测试	48
4.2.3 用户管理功能测试	48
4.2.4 实际应用测试	49
4.3 本章小结	51
第 5 章 总结与展望	52
5.1 总结	52
5.2 未来研究展望	53
参考文献	54
攻读学位期间取得的研究成果	58
致谢	59

第1章 绪论

1.1 研究背景及意义

运动中的年轻人往往有着旺盛的活力和竞争意识,但也容易忽视自身的身体状况和肌肉疲劳的危害。肌肉是人体重要的组成部分,人体的各种运动离不开肌肉。肌肉疲劳是指在肌肉持续收缩活动期间产生肌肉力量的能力下降,进而导致运动能力下降、运动损伤、运动性蛋白尿甚至心血管系统紊乱等后果的现象。因此,对运动中的年轻人进行肌肉疲劳检测,根据检测结果调整运动强度和恢复时间,是避免肌肉损伤和保持身体健康的必要措施^[1]。

根据该领域被广泛接受的学说和较为经典的论文所述,肌肉疲劳的产生原因主要有中枢疲劳和外周疲劳。中枢疲劳是指中枢神经系统的兴奋和抑制失衡,导致运动神经传导受阻或减弱,影响肌肉收缩的调节。中枢疲劳与神经递质(如5-羟色胺、多巴胺、乙酰胆碱等)的变化有关,也与心理因素(如情绪、注意力、动机等)有关。外周疲劳是指从神经-肌肉接头到肌纤维内部各个环节发生功能障碍,导致兴奋-收缩耦联受损,影响肌丝滑行和横桥循环。外周疲劳与代谢产物(如乳酸、无机磷酸盐、氢离子等)的积累有关,也与能量物质(如ATP、糖原等)的消耗有关。当肌肉在运动过程中处于长时间的疲劳状态时,运动损伤的风险就会增加^[2]。因此及时准确地检测肌肉疲劳,是肌肉疲劳的治疗和缓解的基础,具有重要的运动学和医学意义。

肌肉疲劳的检测方法有很多,大致可以分为主观感觉法和生理指标法两类。主观感觉法是根据人的主观感受确定是否疲劳,生理指标法是采集能代表肌肉状态的信号或指标来判断肌肉是否疲劳。在这些方法中,表面肌电信号方法可以用较为便捷的方式采集到包含肌肉力量信息的电信号,因此得到了广泛的应用。

表面肌电信号方法在当前的应用仍存在一些不足之处,表面肌电信号的预处理中会提取出很多特征,然而这些特征的关联性并不明确,因此在识别阶段,输入分类器算法的特征数量过多,会损害分类算法的性能,不利于分类快速性的要求。一般来说,当问题规模特别大时,由于搜索空间巨大且复杂,通常需要大量的计算资源才能获得最优解。为了在肌肉疲劳分类中改进这个问题,研究引入了特征选择方法来提升整体方法的性能。特征选择是对数据进行预处理的算法,通过从数据中筛选出最优特征子集,实现对数据的降维,使模型泛化能力更强,减少过拟合,从而有助于目标任务的学习。

1.2 国内外研究现状

1.2.1 肌肉疲劳识别的国内外研究现状

肌肉疲劳的检测和分类为人机交互、运动损伤和表现、人体工程学和运动医学等领域提供了重要信息,可以检测肌肉疲劳的自动化系统在与运动相关的场景中有极大的用处。在这些场景中,疲劳可能导致受伤。自动化的肌肉疲劳系统可以在疲劳出现之前作为警告装置来指导用户进行训练,同时保持最佳的疲劳状态,从而促进肌肉生长并避免肌肉不必要的拉伤。在职业健康等领域,肌肉疲劳的检测也有重要意义。

目前衡量肌肉疲劳的方法主要有主观感受法和生理指标法。20世纪70年代,瑞典心理学界 Borg 根据受试人员运动时自我对疲劳的感知,提出了主观疲劳等级量表(Rating of Perceived Exertion Scale, RPE)来评估疲劳程度,这种方法简单易行,但不够客观和准确^[3]。生理指标法是根据人体生理参数的变化来评价肌肉疲劳的程度,其中又分为侵入式方法和非侵入式方法。侵入式方法通过对人体血尿素(Blood Urea Nitrogen, BUN)、尿蛋白(Proteinuria, P)、血清睾酮/皮质醇比值(T/C)、血清肌酸激酶(Serum Creatine Kinase, SCK)等生化指标的测量,可以较为准确的反应肌肉疲劳的进程,但在实际应用中由于是有创检验,不仅需要专业的仪器和技术,还很难快速鉴别^[4]。相比之下,非侵入式方法可以兼顾肌肉疲劳检测的准确性、便利性和快速性,通过采集肌肉产生的信号来判断肌肉是否处于疲劳状态。非侵入式方法主要包括肌音信号、肌磁信号、声肌描迹法、近红外光谱法和表面肌电信号方法等^[5]。

生物力学领域的研究中使用了肌音信号(MMG)对肌纤维肌肉疲劳进行识别。肌音信号是从收缩肌肉表面观察到的机械信号,记录着运动时肌肉的振动。Kimura 等^[6]利用肌音信号来研究等长收缩条件下人体肱二头肌和比目鱼肌的疲劳特征,研究结果揭示了肌音信号与肌肉疲劳程度之间的正相关性。然而,该研究也认识到了使用肌音信号的局限性,例如易受运动伪影的影响以及数据解释的困难。

肌磁信号(magnetomyography)是通过记录产生肌电信号的相同离子电流产生的磁场来研究肌肉收缩的生理学方法,其工作原理基于毕奥-萨伐尔定律。肌肉纤维内流动的离子电流产生同心圆形磁场,可以用足够灵敏的磁力计进行记录。因此肌磁信号包含和肌电信号同样丰富的肌肉信息,也可用于肌肉疲劳的研究中。Sometti 等^[7]使用光泵磁力计(OPM)采集了左股直肌的肌磁信号。研究表明,肌磁信号也表现出肌肉疲劳所特有的频谱压缩特征,可以在肌肉疲劳的研究中作为肌电图的替代方案。

声肌描记术(Sonomyography, SMG)使用超声波来描述骨骼肌的结构和形

态变化。Qu 等^[8]设计了一种基于压电微机械超声波换能器 (PMUT) 的可穿戴传感器, 研究持续用力期间上臂肌肉的疲劳动态, 提出了包括初始和二次变形率以及过渡时间等指标用于肌肉疲劳检测中。

近红外光谱 (NIRS) 是一种非侵入性的血流动力学方法, 可以检测皮肤附近的血流变化。NIRS 可以测量疲劳肌肉中的氧合变化, 揭示有关局部血液循环、血容量和收缩肌肉中氧合血红蛋白变化的信息, 从而对肌肉疲劳做出识别^[9]。Yang 等^[10]使用了近红外光谱法来评估肌肉疲劳, 该方法通过分析近红外光穿过组织前后的强度变化来估计氧合血红蛋白和脱氧血红蛋白的相对浓度。研究表明, 近红外光谱法可以提供判断肌肉组织和血液情况的指标, 因此血流动力学方法也可以应用于肌肉疲劳的检测中。然而 NIRS 的应用仅限于浅表组织, 这就限制了其对深层肌肉疲劳进行全面检测的能力。

传统的检测方法在肌肉疲劳识别领域均存在不足, 而表面肌电信号 (sEMG) 方法由于其非侵入性、实用性和实时监测能力, 被广泛应用于肌肉生理学的研究, 成为当下研究的热点。

sEMG 能够提供有关肌肉变化的有价值的信息, 用于测量和分析局部肌肉疲劳。疲劳引起的 sEMG 信号的变化可以在时域或频域进行特征提取。在时域分析中, 表面肌电信号的周期、幅度、功率和积分肌电值的增加反映了在固定的外力下更高的肌纤维募集。在频域分析中, 肌肉疲劳与中位功率频率 (MPF) 有关, 随着肌肉疲劳的加深在低频信号功率略有增加, 高频信号功率相对减少, 低频谱斜率减小, 高频谱斜率增加^[11]。Qassim 等^[13]把肌电信号通过两个带通滤波器滤波产生高频子信号 (HFSS) 和低频子信号 (LFSS), 并计算两个子信号的瞬时平均幅度 (IMA)。文章指出, 在肌肉疲劳发展进程中, HFSS 的 IMA 趋于下降, LFSS 的 IMA 趋于增加。

由于个体之间的肌肉特征存在差异, 没有一个简单的肌肉负荷和时间的函数能够确定一个精确的肌肉疲劳阈值, 因此使用 sEMG 对肌肉疲劳问题进行分析研究时多伴随使用机器学习等监督学习方法。Wang 等^[14]使用改进的小波阈值方法对测量的 sEMG 信号进行去噪, 提取表面肌电信号的时域特征和频域特征, 包括均方根、积分肌电图、中频、平均功率频率和频带谱熵等作为数据集, 训练 CNN-SVM 融合分类方法对下肢肌肉的 sEMG 进行疲劳检测。Liu G 等^[15]提出了一种基于 FGNN 算法的 sEMG 肌肉疲劳分类方法, 该方法首先对果蝇算法进行了改进, 并将遗传算法与果蝇优化算法浓度的步交叉和变异相混合, 与神经网络相结合来识别肌肉疲劳。Mu 等^[16]采用时间卷积网络对 sEMG 和 ECG 融合数据进行研究以检测运动肌肉疲劳, 研究通过信号预处理和序列归一化获得相同长度的表面肌电和心电时间序列, 通过基于序列卷积的深度学习网络实现序列时态特

征提取,并根据 DS 证据理论建立肌肉疲劳评估的信号融合模型。Zhang 等^[17]使用基于多维特征融合网络(MFFNet)的 sEMG 信号来检测肌肉疲劳,该网络由注意力频域网络(AFNet)和注意力网络组成时域网络(ATNet)。其中,AFNet 由卷积神经网络、通道注意力网络和空间注意力网络组成。ATNet 由双向长短期记忆网络和时间注意力网络组成。Liu 等^[18]采用差分进化(DE)算法来生成更合适的初始种群,改进了鲸鱼优化算法(WOA),建立了结合支持向量机(SVM)的精确分类模型,以适应动态条件下的肌肉疲劳预测。Wang 等^[19]利用改进的小波包阈值去噪算法提取去噪后的表面肌电信号的时域和频域特征,提出了一种基于长短期记忆(LSTM)网络的新的肌肉疲劳识别模型。Liu 等^[20]提出了一种结合了传统的卷积神经网络(CNN)、长短期记忆网络(LSTM)和 Transformer 编码器的 CLT 模型,通过提取表面肌电信号的近似熵(ApEn)和排列熵(PE)两个非线性特征对上肢肌肉的疲劳状况进行分析检测。

除了对 sEMG 的时域特征和频域特征展开研究,也有学者从生物机理角度对 sEMG 在肌肉疲劳识别领域的应用展开研究。中岛浩介等^[21]基于肌电信号和肌纤维类型使用率,提出了一种肌肉疲劳判断的指标——肌肉疲劳时间(MFT),MFT 是慢肌纤维(I型)和快肌纤维(IIb型)的使用比率相交的时间。

表面肌电方法的便捷性使其有较高的实用价值。González-Zamora 等^[22]设计了一种基于肌电信号测量肌肉疲劳程度可穿戴设备,该设备使用平均频率和功率谱密度作为肌肉疲劳测定特征,使用线性回归模型确定肌肉疲劳程度。然而,为了提高最终设计设备的识别准确率,大多数方法并没有考虑实际的成本,因此限制了设备的实际应用范围。

目前的研究结果显示,基于表面肌电信号(sEMG)的肌肉疲劳识别方法在特征选择和实际应用方案设计两个方面仍面临着挑战。首先,在特征选择方面,由于肌电信号携带了大量的肌肉信息,因此可以从中提取出多种不同的特征。然而,现有的研究主要集中在如何从 sEMG 信号中筛选出最具影响力的特征,以显著提高预测精度,而忽略了特征维数和预测精度之间的平衡问题。其次,在实际应用方案设计方面,大多数设计为了提高预测精度而增加了传感器的数量,这导致了成本的增加,限制了产品的实际应用^[23]。因此,有必要研究一种稳定可靠的肌肉疲劳识别方法,该方法在保证识别准确度的基础上,尽可能地减少特征和传感器的使用,以提高设备的实用性。

1.2.2 特征选择方法的国内外研究现状

近年来,随着信息产生的速度和信息量的不断增加,维数灾难成为了模式识别和机器学习领域中不可避免的巨大挑战。由于机器学习算法的性能很大程度上

收到特征数量和数据维度的影响,特征选择受到了越来越多的关注。依据特征选择方法与后续分类模型的关系,特征选择的相关方法可以分为两大类,即过滤式方法和包裹式方法。

在过滤式(Filter)特征选择方法中,根据数据集的统计和内在特征的某些标准对特征进行排序和评估。在过滤方法中,分类器和数据集之间没有联系。在此类方法中,根据特征与目标的相关性对特征进行排序,并根据特征之间的相关性过滤掉不相关的特征。

常见的过滤式方法有 ReliefF 算法、主成分分析法、互信息法和基于矩阵的方法等。ReliefF 算法是一种在特征选择问题中特征权重算法,可以根据各个特征和类别的相关性赋予特征不同的权重,权重小于某个阈值的特征将被移除,具有运行效率高的特点^[24]。主成分分析算法是一种正交变化方法,经常用于减少数据集的维数,同时保留数据集中对方差贡献最大的特征^[25]。互信息法是一种单变量特征选择方法,它对每一个特征和目标变量之间进行统计检验,衡量相关性,去除得分低的特征^[26]。在基于矩阵的技术的特征选择中,目的是寻求一个比原始空间具有更低维度的子空间。原始空间与其子空间之间的距离可以使用豪斯德罗夫距离、定向距离和弗罗贝尼乌斯范数基距离测量,搜索与原始空间距离最小的子空间过程即特征选择的过程^[27]。过滤式方法尽管消耗的计算资源较少,但是降维效果较差,分类准确率较低。

包装式(Wrapper)特征选择与过滤式方法有所不同,过滤式方法不需要考虑后续的学习器,而包装式是依赖于所选择的学习算法,特征子集的评价准则采用即将使用的学习器的性能^[28]。因此,包裹式算法通常能够得到具有更高的分类精度的特征子集。Sindhwani 等^[29]使用类标签和分类器之间的互信息作为目标函数,将多类支持向量机与多层感知器联系在一起,提出了一种基于最大输出信息的高效的包装式特征选择算法,该算法通过贪婪消除和定向搜索来选择特征子集。Liu 等^[30]通过样本图和特征树联合学习底层样本关系和特征关系,使用基于关系的序列浮动选择策略选择特征子集,提出了一种关系感知特征选择方法(ERASE)。

特征选择被归类为组合 NP 难问题,遍历所有特征子集将耗费巨大的时间和算力。因此,随机搜索特征子集,并通过特定的迭代方法对其进行改进,从而生成候选子集的方法被广泛应用。启发式搜索作为另一种类型的搜索方法,也被广泛应用于特征选择问题中。由于能够在较短的时间内解决特征选择问题,元启发式算法在过去十年中引起了越来越多的关注^[31]。Samieiyan 等^[32]使用新型乌鸦算法对数据进行降维,使用动态感知概率来保持局部和全局搜索过程之间的平衡,还引入了一种新颖的邻域分配策略来优化局部搜索。该算法提升了分类器的泛化

能力,从而提高了分类准确率。Souza 等^[33]使用一种最先进的深度 CNN 模型 SigNet,用于手写签名验证的特征提取,并引入二进制粒子群优化(BPSO)方法对特征进行降维,解决了手写签名验证(HSV)中的过拟合问题。Yu 等采用自适应混沌突变和贪心选择算法对自适应排名飞蛾火焰优化算法(ARMFO)进行了改进,提高了在该算法在特征选择问题中的搜索能力^[34]。

启发式算法在特征选择领域有着良好的表现,但是它们也存在一些缺陷。首先,它们在迭代过程中容易陷入局部最优,导致每次选出的特征子集不稳定,变化较大。其次,由于特征之间有着复杂的联系,它们在开发和探索时往往会忽视数据集中的关键信息,比如分类问题中特征之间和特征与样本类别之间的关系,这使得它们的搜索缺乏目的性和方向性,导致收敛结果不理想^[35]。因此,如何在减少特征维数的同时,提高特征选择的稳定性,从而提高肌肉疲劳识别的精度,是一个值得研究的问题。

1.3 本论文工作概述及章节安排

本论文的主要研究工作包括三个部分,这些工作共同构成了基于表面肌电信号的肌肉疲劳识别方法的完整研究框架,具体工作内容如下:

(1) 疲劳诱发实验的设计。本研究开展了肌肉疲劳诱发实验,旨在通过哑铃负重训练诱发参与者的肌肉疲劳,并采集肱二头肌的表面肌电信号。实验中采用了主观疲劳等级量表(RPE)作为疲劳等级的划分依据,将表面肌电信号标注为轻松态、疲劳过渡态和疲劳态。此外,对原始信号进行了时间窗口划分,并对处理后的信号进行了特征提取,为后续的分类分析奠定了基础。

(2) RNA 算法的建立和验证。针对表面肌电信号特征数量众多可能导致的分类器性能下降问题,采用了基于 ReliefF-NOCSA-AdakNN 的新型融合式算法,对经过滤波处理的肱二头肌肌电信号数据进行了有效的特征选择和分类。通过对比实验和消融实验,本研究证明了 RNA 算法在减少特征数量和提高分类准确率方面的优越性。

(3) 识别系统的构建。本研究设计并实现了一套软硬件系统,用于处理和分类肌肉疲劳信号以及数据的存储。该系统不仅能够实时采集 sEMG 信号,还能够利用 RNA 算法实现肌肉疲劳状态的实时识别,为肌肉疲劳的监测和评估提供了一种有效的工具。

本文共分为五章,具体的章节安排如下:

第一章:绪论。本章首先阐述了本课题的研究背景与重要性,突出了表面肌电信号(sEMG)技术在肌肉疲劳识别中的应用潜力。接着,综述了 sEMG 在肌肉疲劳识别领域的国际及国内研究进展,并分析了当前 sEMG 处理方法存在的

挑战。本章还详细讨论了特征选择技术的发展趋势，并以此为契机深入探讨相关问题。最终，本章明确了本文的研究目标及章节结构。

第二章：肌肉疲劳识别模型建立。本章首先介绍了肌肉疲劳分析的理论基础，包括信号的采集、数据分割和特征提取等关键步骤。针对肌肉疲劳领域当前面临的诸多问题，本研究提出了一种基于 ReliefF-NOCSA-Ada-kNN (RNA) 的创新融合算法。该算法有效降低了特征的冗余性，并确保分类过程的高精度。通过消融实验和对比实验验证了该算法的有效性和竞争力。

第三章：肌肉疲劳识别系统设计。本章基于 STM32 硬件平台，配合 Ag-AgCl 表面电极，设计并实现了一套完整的肌电信号采集系统，保证了信号的实时传输。此外，本章还介绍了基于 .NET Framework 开发的上位机软件系统，该系统集成了串口通信、波形显示、疲劳识别等模块，实现了数据的有效处理，并采用 RNA 算法实时监测肌肉疲劳状态。

第四章：肌肉疲劳识别实验与系统测试。本章详细描述了肌肉疲劳诱发实验的设计流程，并收集了不同参与者在肌肉疲劳状态下的 sEMG 信号，对这些信号进行了特征分析。本章还对所设计的软硬件系统进行了全面测试，验证了系统的有效性和实用性。

第五章：总结与展望。本章总结了全文的研究内容和主要成果，并对研究过程中遇到的问题进行了反思。基于当前研究的局限性，本章提出了未来工作的可能改进方向和研究展望。

本文的架构图如图 1-1 所示。




图 1-1 论文架构图

第2章 肌肉疲劳识别模型建立

在本章中，我们首先介绍了一种 sEMG 数据分割方法，旨在更好地反映原始信号的特征变化并增加样本数量。随后，我们对分割后的数据进行了时域和频域分析，以提取尽可能多的特征。然而，这些特征中可能存在一些冗余和不相关的成分，这会增加计算的复杂度并降低分类器的学习性能。为了解决这一问题，本章提出了一种基于 ReliefF、NOCSA 和 Ada-kNN 的融合式算法，从而建立了一个有效的肌肉疲劳识别模型。最后通过对比实验和消融实验验证了所提出算法的有效性。

2.1 表面肌电信号数据分割

在表面肌电信号（sEMG）的处理中，数据分割是提高特征提取效率和分类器训练效果的关键步骤。原始 sEMG 信号通常包含大量数据，如果不进行分割，特征提取将只能得到单一的特征值，不利于后续的模式识别和分类。此外，长时间采集的 sEMG 信号会导致数据量过大，处理和响应时间长，影响算法的实时性。常用的数据分割方法有滑窗分割法和无重叠分割法。

滑窗分割是一种常用的数据分割方法，通过在信号上滑动固定长度的窗口，并以一定的步长移动这些窗口，从而将连续的信号分割成多个段。每个窗口的长度和滑动步长是该方法的两个关键参数。步长则决定了分割后信号的维度和原始数据的压缩比例。滑窗分割能够在保持数据连续性的同时，提供多个样本用于训练分类器，从而提高分类的准确性。无重叠分割则是将原始信号等分成多个长度相同的段，每个段之间没有重叠。这种方法的步长等于窗口长度，操作简单，易于理解。然而，这种分割方式的一个主要缺点是分割后的样本数量较少，可能不足以训练出一个高效的分类器。

综合上述内容，本文选择滑窗分割方法对表面肌电信号进行分割。在 Englehart 等^[36]的研究中指出，为了使每个样本包含足够丰富的信息，可以使用窗口的长度应选取在 200ms-300ms 之间的滑窗分割方法。而本研究所使用的采样系统的采样率为 2000Hz，为了提高样本数量，采用的数据分割方案为窗口长度为 200ms（即 400 个采样点），步长为 40ms（即 80 个采样点）。

对于单个的 sEMG 数据，分割后得到的样本个数 N 计算如公式(2-1)所示：

$$N = \frac{X - 400}{80 + 1} \quad (2-1)$$

其中 X 为分割前 sEMG 数据的总长度。

2.2 表面肌电信号特征提取

2.2.1 特征计算

sEMG 信号的分析主要集中在时域和频域。部分特征在已有的文献研究中对肌肉状态识别具有重要意义，并广泛应用于肌电信号的特征表示。

经典的时域特征包括均方根值、积分肌电值、方差、修正的平均绝对值和过零率等，这些特征的解释如下：

均方根值（Root mean square, RMS）是一段时间内 sEMG 的平均变化特征，均方根值越高，表明肌肉收缩和放松能力越差，疲劳程度越高。均方根值的表达式如公式(2-2)所示。

$$RMS = \sqrt{\frac{1}{N} \sum_{i=1}^N x_i^2} \quad (2-2)$$

积分肌电值（Integrated EMG, iEMG）是表面肌电信号单位时间内线下面积的总和，用来反映肌电信号的振幅特征。通常其幅值越大，疲劳程度越重。积分肌电值的表达式如公式(2-3)所示。

$$iEMG = \sum_{i=1}^N |x_i| \quad (2-3)$$

方差（Variance of EMG, VAR）是反应表面肌电信号离散程度趋势的一种时域分析指标，他表示表面肌电信号与其平均值之间的差异大小。方差越大，说明肌电信号的波动越大，反映肌肉收缩的不稳定性。方差表达式如公式(2-4)所示。

$$VAR = \frac{\sum_{i=1}^N (x_i - \bar{x})^2}{N} \quad (2-4)$$

修正的平均绝对值（Modified mean absolute value type 2, MAV2）是指表面肌电信号的绝对值减去其平均值的平均值，用来刻画表面肌电信号的振幅特征。修正的平均绝对值表达式如公式(2-5)所示。

$$MAV2 = \frac{1}{N} \sum_{i=1}^N w_i |x_i| \quad (2-5)$$

式中 w_i 为权重，

$$w_i = \begin{cases} 1, & 0.25N \leq i \leq 0.75N \\ \frac{4i}{N} & i < 0.25N \\ \frac{4\left(\frac{i}{N}\right)}{N} & otherwise \end{cases}$$

过零率（Zero Crossing Rate, ZCR）是指表面肌电信号穿越零电平的次数，它用来描述波形在幅度变化上的剧烈程度，反映了信号的变化趋势。过零次数表达式如公式(2-6)所示。

$$ZCR = \sum_{i=1}^{N-1} [sgn(-x_i x_{i+1}) \cap |x_i - x_{i+1}| \geq threshold] \quad (2-6)$$

其中 $sgn(x) = \begin{cases} 1, x \geq threshold \\ 0, otherwise \end{cases}$

经典的频域特征包括平均功率、中值功率和平均功率频率等，这些特征的解释和公式如下：

平均频率（Mean Frequency, MNF）是指表面肌电信号在频域上的平均值，它反映了肌电信号的频率特性。平均频率可以用来评价肌肉疲劳的程度，一般来说，肌电信号的平均频率随着运动时间的增加而逐渐降低。平均频率的表达式如公式(2-7)所示。

$$MNF = \frac{\sum_{i=0}^{N-1} f_i \times P_i}{\sum_{i=0}^{N-1} P_i} \quad (2-7)$$

中值频率（Median Frequency, MF）是指表面肌电信号的功率谱的中位数，是量化低频分量的指标。它反映了表面肌电信号的频率分布。中值频率的表达式如公式(2-8)所示。

$$MDF = \frac{1}{2} \sum_{i=1}^{N-1} P_i \quad (2-8)$$

平均功率频率（Mean Power Frequency, MPF）是一种基于频域的肌电信号特征提取方法，它反映了肌电信号的能量随频率的变化情况。肌电信号平均功率频率越大，说明肌电信号的能量集中在高频区域，反之则集中在低频区域。平均功率频率的表达式如公式(2-9)所示。

$$MPF = \frac{\sum_{i=1}^n f_i P_i}{\sum_{i=1}^n P_i} \quad (2-9)$$

除此之外，本研究通过 MATLAB 工具箱对采集到的肱二头肌肌电信号提取了共计 33 种特征^[37]。

2.2.2 特征选择

在利用特征提取方法对表面肌电信号进行处理之后，每一个表面肌电信号的特征都可以用一个特征向量表示成如公式(2-10)所示形式^[38]。

$$X = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_d \end{bmatrix} \in R^d \quad (2-10)$$

式中， d 是特征向量的维数。

由上述特征向量所组成的空间称为特征空间，它反映了数据的内在结构和属性。特征提取是一种从原始数据中生成特征向量的方法，但通常会导致特征空间的维数过高，影响分类器的输入和输出效果。为了提高分类的准确性和泛化能力，简化分类器的设计，降低特征空间的维数是必要的。目前，常用的降维方法有两种：特征选择和特征变换。特征选择是从原始特征中选取一部分与分类相关的特征，以减少特征的数量和计算的复杂度，但可能会损失一些分类信息。特征变换是通过对原始特征进行某种变换，生成一组新的特征，以保留更多的分类信息，但需要更多的计算资源，可能不适合实时的分类任务^{[39][38]}。综合考虑各种因素，本文采用特征选择方法对肌电信号特征进行降维处理。特征选择是一种从原始数据中筛选出与分类任务相关的特征的方法，它可以降低特征空间的维数，提高分类的效率和准确性。如图 2-1 所示，特征选择的一般流程包括以下四个步骤：




图 2-1 特征选择流程

(1) 生成候选子集：这一步骤是根据特定的搜索策略，从数据集中选择一部分特征，形成特征子集，供后续的评价函数使用。搜索策略的选择会影响搜索的范围和速度，常见的搜索策略有三种，分别是全局遍历搜索、启发式搜索和随机搜索。

(2) 子集评估：这一步骤是根据特定的评价准则，对特征子集进行评估，得到评价指标。评价准则的选择会影响评价的标准和结果，常见的评价准则有两种，分别是独立准则和关联准则。独立准则是指与学习算法无关的评价准则，它

只依赖于特征子集本身的特性,如信息度量、距离度量、关联性度量和一致性度量等,这种准则的优点是运行速度快,缺点是可能会忽略一些对分类有用的特征。关联准则是指与学习算法有关的评价准则,它需要将特征子集作为学习算法的输入,然后根据学习算法的输出性能,如分类准确率、分类时间等,来评价特征子集的优劣,这种准则的优点是评价结果更贴近分类任务的目标,缺点是运行速度慢,且不具有通用性。

(3) 终止条件:这一步骤是确定算法何时停止搜索的条件,它与评价函数密切相关,常用的终止条件有执行时间、迭代次数或准则阈值等。

(4) 结果验证:这一步骤是验证所选特征子集的有效性,它可以通过先验知识或对验证集实验的结果进行分析。

2.3 基于 RNA 算法的肌肉疲劳识别模型建立

由上文中的分析可知,为了在肌肉疲劳识别领域追求更高的精准度和实时性,需要选择合适的特征选择算法和分类器。本节中介绍了一种融合算法,即 ReliefF-NOCSA-AdakNN 算法。该算法由三个组件组成,分别是过滤器算法 ReliefF,启发式算法 NOCSA 和分类器 Ada-kNN,这三个组件集成到一起的原理是因为它们相互补充。ReliefF 结构可以根据各个特征的类别和相关性赋予特征不同的权重,完成对特征的初步筛选。NOCSA 结构可以产生具有多样性的候选子集。Ada-KNN 结构可以评估特征子集的分类效果,计算出适应度值,并且不断更新局部最优解和全局最优解,直到达到终止条件,以获取识别效果最好的特征子集。

2.3.1 基于 ReliefF 算法的特征权重估计模型

针对肌肉疲劳识别中不同肌电特征的关联紧密度差异,在 RNA 算法中首先使用 ReliefF 根据特征的类别和相关性赋予特征权重,进行初步筛选。

Relief 是一种特征加权算法,最初仅限于解决二元分类问题。Relief 算法根据每个特征与类别的相关性为特征分配不同的权重,权重小于一定阈值的特征被拒绝。ReliefF 是原始 Relief 的改进版本,专门为处理多类问题而设计。ReliefF 简化了 Relief 的大部分思想。ReliefF 的主要目的是提高分类的准确性,特别是在高维数据上。它还可以处理不完整的特征和干扰特征。该算法基本思想是:给定标签有 l 类 $c = [c_1, c_2, \dots, c_l]$ 。ReliefF 从训练集中随机选择一个样本 R_i , 然后发现 K 的近似样本 R_i 来自同一类别,表示为 $H_j (j = 1, 2, 3, \dots, K)$, 并且还发现 K 的近似样本 R_i 来自不同类表,表示为 $M_j(C) (j = 1, 2, 3, \dots, K)$ 。ReliefF 在每个特征维度上重复上述步骤,得到每个特征的权重如公式(2-11)所示:

$$W(A) = W(A) - \sum_{j=1}^k \frac{diff(A, R, H_j)}{mk} + \sum_{C \notin class(R)} \frac{\frac{p(C)}{1 - p(class(R))} \sum_{j=1}^k diff(A, R, M_j(C))}{mk} \quad (2-11)$$

式中 $diff(A, R, H_j)$ 表示样本 R_1 和 R_2 在特征 A 上的差, $M_j(C)$ 表示类 $C \notin class(R)$ 中第 j 个最邻近样本。如公式(2-12)所示。

$$diff(A, R_1, R_2) = \begin{cases} \frac{|R_1[A] - R_2[A]|}{\max(A) - \min(A)} & \text{If } A \text{ is Continuous} \\ 0 & \text{If } A \text{ is Discrete And } R_1[A] = R_2[A] \\ 1 & \text{If } A \text{ is Discrete And } R_1[A] \neq R_2[A] \end{cases} \quad (2-12)$$

2.3.2 基于 NOCSA 算法的特征筛选模型

NOCSA 可以进一步对排序后的特征子集进行选择从而得到较好的分类效果和较高的运算效率。NOCSA 是一种基于乌鸦社会行为(即乌鸦隐藏食物的机制)的元启发式算法。乌鸦可以隐藏食物并记住他们的位置几个月。他们生活在一个群体中, 每个乌鸦都试图找到其他乌鸦食物的藏身之处。此外, 乌鸦通过定期更换藏身之处来保护食物。这两种位置的更新方式分别对应 NOCSA 算法的本地搜索和全局搜索。乌鸦位置的更新可以用公式(2-13)表示。

$$Y_j^{t+1} = \begin{cases} Y_j^t + C_t \times fl_j^t \times (N_i^t - Y_j^t) & r_j > qAP_j^t \\ \text{Select a random position} & \text{Otherwise.} \end{cases} \quad (2-13)$$

其中 fl_j^t 是乌鸦的飞行长度, C_t 为混沌函数, N_i^t 为邻居记忆, Y_j^t 为乌鸦的当前位置。混沌函数是基于正弦函数构建的, 如公式(2-14)所示。混沌函数的使用提高了算法的收敛速度。

$$C_t = \begin{cases} \sin(\pi C_{t-1}) & t > 1 \\ 0.7 & t = 1 \end{cases} \quad (2-14)$$

为了解决该算法局部搜索和全局搜索之间的不平衡, 从而陷入局部最优, 因此引入了 Gong 提出的动态认知概率机制(DAP)^{[40][40]}。DAP 技术的主要思想是局部搜索适应度强的乌鸦, 而全局搜索适应度弱的乌鸦, 以跳出局部最优解。DAP 的定义如公式(2-15)所示。

$$DAP_i = AP_{min} + (AP_{max} - AP_{min}) \times \frac{rank_i}{N} \quad (2-15)$$

其中 $rank_i$ 是乌鸦 i 在所有乌鸦中的排名, N 是乌鸦总数。 AP_{min} 和 AP_{max} 分别是 AP 的下限和上限。

根据乌鸦的行为,研究使用了一种二进制模型来映射特征选择问题。算法的输入是由二进制字符串组成的乌鸦,算法输出表示为所选特征的二进制字符串。即1表示该特征被选中,0表示该特征不被选中。在本研究中使用V2传递函数将连续值转换为二进制值。同时,算法引入了适应度函数来衡量特征选择的效果,适应度函数定义如公式(2-16)所示。

$$fitness = Acc + \alpha \times \left(1 - \left(\frac{L_s}{L_t}\right)\right) \quad (2-16)$$

在该公式中,Acc是使用下文介绍的Ada-KNN算法得出的分类准确率。 L_s 和 L_t 分别表示所选特征和总数据集特征, α 为权重参数,用来权衡准确性和所选特征的数量。 α 越大,算法倾向于选择较少的特征,这会对精度产生不利影响。本研究中 α 选择0.2。适应度数值越高,乌鸦的位置就越好。此外,在每次迭代中根据帕累托最优选择最佳乌鸦有助于提高算法的性能。

NOCSA 算法的流程伪代码如算法1所示:

算法1 NOCSA 算法

1:	初始化乌鸦飞行距离 fl , 最大迭代次数 t_{max} , 搜索代理数 SA 和动态认知概率限制 DAP_lim
2:	初始化混沌函数(公式 2-14)
3:	搜索代理进行二进制初始化(即初始化乌鸦位置)
4:	根据每一只乌鸦的位置分别计算其适应度
5:	根据适应度值对乌鸦进行排序
6:	计算每只乌鸦的动态认知概率 DAP (公式 2-15)
7:	初始化乌鸦记忆
8:	设置当前迭代 $t = 1$
9:	while $DAP_i < DAP_lim$ do
10:	for $i = 1:10$ do
11:	for $j = i + 1:i + 10$ do
12:	if $DAP_i < DAP_lim$ then 执行本地搜索
13:	随机生成新乌鸦
14:	使用 V2 传递函数对乌鸦位置进行离散化以生成二进制序列
15:	else 执行全局搜索
16:	创建具有 20%特征的随机子集
17:	$new_{crow} = best_{crow} \mid$ 随机子集(与已知最佳子集合并)

18:	使用 V2 传递函数对乌鸦位置进行离散化以生成二进制序列
19:	end for
20:	end for
21:	计算每只新乌鸦的适应度
22:	位置更新（公式 2-13）
23:	使用帕累托最优选择下一个乌鸦群
24:	end while
25:	得出最优乌鸦种群（即最优解）

2.3.3 基于 Ada-kNN 算法的分类器模型

K 邻近分类（kNN）算法因其方法简单、非参数工作原理和易于实现而一直有着广泛应用^[41]。kNN 分类器涉及超参数 k（即要考虑的最近邻居的数量）的调整。然而，要找到 kNN 分类器在各种数据集上的表现最佳的 k 值并不容易。此外，kNN 分类器在对类别数量不平衡的数据集进行分类时也有着问题。本文运用加入了前馈多层感知器（MLP）和全局不平衡处理方案（GIHS）的 Ada-kNN 算法验证 NOCSA 中乌鸦的位置的优劣，并且作为分类器对肌肉疲劳状态进行识别^[42]。

kNN 的基本分类规则可以表示为公式(2-17)。

$$\hat{c}(y_i) = \arg \max_{c \in \{1, 2, \dots, C\}} \sum_{x_i \in \Gamma_k^P(y_i)} I(c^{(x_i)} = c) \quad (2-17)$$

其中， $c^{(x_i)} \in C$ 为训练样本点 $x_i \in P$ 的类别标签， $i = 1, 2, \dots, n$ 。属于 c 类的所有训练样本点的集合用 C_c 表示，并且 $|C_c| = n_c$ 。对于测试样本点 y_i ，如果 kNN 训练集 P 中 y_i 形成集合 $\Gamma_k^P(y_i)$ ，则 y_i 的预测类标签为 $\hat{c}(y_i)$ 。 $I(\cdot)$ 为指示函数，定义如公式(2-18)所示，其中 cond 是需要满足的某个条件。

$$I(\text{cond}) = \begin{cases} 1, & \text{if cond is true} \\ 0, & \text{if cond is false.} \end{cases} \quad (2-18)$$

Ada-kNN 分类器利用测试点的邻域信息，通过引入特定点 k 值的概念来解决 k 的全局选择问题。实现此目的的一种方法是找到正确分类每个训练样本点 $x_i \in P$ 的 k 值集合，并使用监督学习方法前馈多层感知器（Multi-Layer Perceptron, MLP）将 k 值建模为其相应训练向量的非线性函数。然后可以将该函数应用于测试样本点以确定适合它的 k 值。

为了对类别不平衡数据集进行处理，Ada-kNN 定义了一个简单的全局不平

衡处理方案 (Global Imbalance Handling Scheme, GIHS)。我们把传统的 kNN 算法的每一个类的权重相关联。如果第 c 个类的权重由 w_c 表示, 则加权 kNN 分类规则可以表示为公式(2-19)。

$$\hat{c}(y_i) = \arg \max_{c \in 1, 2, \dots, C} \sum_{x_i \in \Gamma_k^P(y_i)} w_c I(c^{(x_i)} = c) \quad (2-19)$$

衡量类别权重的一种方法是使用全局类别加权方案, 该方案对所有测试样本点使用相同的类别权重集。由于理想情况下 P 中每个类的代表数量应该相等, 因此属于类 $c \in C$ 的点的理想概率应该是 $r = (1/C)$ 。但是大多数数据集并不理想。因此, 我们有属于 c 类的 n_c 训练样本点 (其中 n_c 的值并非全部相等)。因此 $\sum_{c=1}^C n_c = n$, 并且类 c 的先验概率等于 $p_c = (n_c/n)$ 。为了使每个类别在测试样本点附近有公平的机会, 避免类别不平衡的影响, 我们把类别 c 的理想概率和当前概率的比指定为该类别相关的全局权重 w_c , 即公式(2-20)所示:

$$w_c = \frac{r}{p_c} \quad (2-20)$$

Ada-kNN 的算法伪代码如算法 2 所示。

算法 2 Ada-kNN 算法

1:	对于所有样本点 $x \in P \cup Q$, 使用训练集 P 和公式 2-20, 计算集合的全局权重 $W = \{w_1, w_2, \dots, w_C\}$
2:	定义 $k_{max} = \sqrt{n}$, $K = \{1, 2, \dots, k_{max}\}$
3:	训练阶段:
4:	for all $x_i \in P$ do
5:	$K'_{x_i} = \text{TrainRoutine}(P, W, K, x_i)$
6:	end for
7:	用 x_i 作为输入, 期望的超参数 k_{x_i} 作为输出, 训练多层感知机 MLP
8:	测试阶段:
9:	for all $y_i \in Q$ do
10:	把 y_i 输入至已经训练好的多层感知机中, 获取输出 k_{y_i} .
11:	用 P, W, k_{y_i} 对 y_i 进行分类, 获取类别 C
12:	end for

2.4 RNA 算法评估实验

本节旨在验证提出的 RNA 算法在表面肌电信号分类上的优越性和有效性。为此, 我们设计了对比实验和消融实验, 分别从整体和局部的角度, 对 RNA 算法的三个核心组成部分 (ReliefF、NOCSA、Ada-kNN) 进行了深入的分析和评估。

为了保证实验的公正性和客观性,对所有算法的性能指标进行了30次独立重复实验的平均值。研究采用五折交叉验证的方法来训练和测试监督学习分类器,即将数据集随机划分为5个等大小的子集,每次选取其中4个子集作为训练集,剩余的1个子集作为测试集,以此来验证各个算法的分类效果。

2.4.1 评价指标

为了评价研究的RNA算法的性能,本文定义了以下的指标。

分类准确率(Acc)为分类正确的样本占样本总数的比例,如公式(2-21)所示。

$$Acc = \frac{\text{Correctly classified samples}}{\text{total samples}} \times 100\% \quad (2-21)$$

平均分类准确率($\overline{Acc}$)为 N_y 次算法独立运行中获得的准确率的平均值,如公式(2-22)所示。

$$\overline{Acc} = \frac{1}{N_y} \sum_{k=1}^{N_y} Acc_k \quad (2-22)$$

本研究定义了一个适应度函数(Fit),它与提取出的特征比例和准确度有关,如公式(2-23)所示。

$$Fit = \alpha * (1 - Accuracy) + (1 - \alpha) * \left(\frac{\text{the num of selected features}}{\text{Total num of the features}} \right) \quad (2-23)$$

平均适应度结果($\overline{Fit}$)为 N_y 次算法独立运行中获得的适应度的平均值,如公式(2-24)所示。

$$\overline{Fit} = \frac{1}{N_y} \sum_{k=1}^{N_y} fitness_{best}^k \quad (2-24)$$

标准差(STD)表示一组数据的离散程度,如公式(2-25)所示。

$$STD = \sqrt{\frac{1}{N_y} \sum_{k=1}^{N_y} (M_k - \overline{M})^2} \quad (2-25)$$

其中, M 的值由分类准确率和适应度值确定。

平均执行时间($\overline{CT}$):表示算法运行 N_y 次所用的平均CPU时间(单位为秒),如公式(2-26)所示。

$$\overline{CT} = \frac{1}{N_y} \sum_{k=1}^{N_y} CT_k \quad (2-26)$$

为了检验分类器的效果，额外使用了 $F1 - score$ 来衡量分类器的分类能力。如公式(2-27)所示：

$$F1 - score = 2 \frac{Precision \times Recall}{(\beta^2 \times Precision) + Recall} \quad (2-27)$$

其中 $Precision$ 为准确率， $Recall$ 为召回率，其计算公式如下：

$$Precision = \frac{TP}{TP + FP} \quad (2-28)$$

$$Recall = \frac{TP}{TP + FN} \quad (2-29)$$

$$ACC = \frac{TP + TN}{TP + TN + FP + FN} \quad (2-30)$$


其中 TP 表示实际值和预测值均为正值的样例数， FP 表示实际值为负值且预测值为正值的样例数， TN 表示实际值和预测值均为负值的样例数， FN 表示实际值为正且预测值为负的样例数。

2.4.2 ReliefF 实验结果分析

本文首先采用 ReliefF 作为特征选择的第一步，目的是剔除与分类无关或冗余的特征，从而降低计算复杂度，提高计算效率。ReliefF 中的阈值参数 λ 对算法性能有着重要的影响。为了寻找最优的 λ 值，本文参考了文献^[43]中的阈值选择方法，将 λ 分别设定为 25%，50%，75%和 100%，并且使用五位受试者的数据进行了实验，得到了不同 λ 值下的候选特征集，然后使用 kNN 分类器对特征选择的效果进行了评估。图 2-2 和表 2-1 展示了 λ 的不同取值对识别精度的影响。

表 2-1 ReliefF 算法选取不同阈值 λ 获得的识别精度

Data set	$\overline{Acc}$ (%)			
	$\lambda = 25\%$	$\lambda = 50\%$	$\lambda = 75\%$	$\lambda = 100\%$
Sample 1	72.53	83.36	84.64	85.32
Sample 2	68.00	78.57	80.69	93.82
Sample 3	73.18	79.81	82.20	83.46
Sample 4	70.54	81.13	80.01	82.83
Sample 5	65.72	82.11	83.45	83.60
Average	69.99	80.99	82.19	85.80

图 2-2 λ 对于识别精度的影响

从图表中看出，当 λ 为 50% 时，所有样本的分类精度均达到了较高的水平（平均为 80.99%）。随着 λ 的增大，分类精度的提升幅度逐渐减小。这说明，当 λ 为 50% 时，可以有效地去除原始特征集中的一半无关特征，从而减少后续分类的干扰因素。

2.4.3 RNA 算法消融实验分析

本研究为了验证所提出的特征选择融合算法的有效性，设计了一系列的消融实验，通过比较 RNA 算法的不同组合方式，来分析其对分类性能的影响。本部分中，我们考虑了三种不同的融合方式，分别是仅使用 Ada-kNN 分类器，ReliefF+Ada-kNN 算法和 ReliefF+ NOCSA+ Ada-kNN 算法，并且根据分类精度和特征减少率的结果来评价这三种方法的优劣。表 2-2 中给出了本研究算法和对比算法的相关参数设置，所有参数的选取均基于小规模模拟实验或者文献中的先验研究。表 2-3 中展示了三种算法的平均分类准确率和标准差。表 2-4 中展示了所选特征的个数、平均适应度和运行时间。为了方便比较，我们将三种对比算法的运行时间进行了归一化处理，并且以 RNA 算法的运行时间为单位。

本研究通过对比 ReliefF+ Ada-kNN 算法、RNA 算法和不使用特征选择的算法，来验证所提出的融合算法的有效性。实验结果表明，ReliefF+ Ada-kNN 算法在分类精度上表现最佳（84.34%），RNA 算法和不使用特征选择的算法相差不大（分别为 83.88% 和 83.85%）。在运行时间上，由于特征的减少，RNA 算法比不使用特征选择的算法节省了 11% 的时间。RNA 算法能够剔除一半以上的无关

特征，只保留了 11 个有效特征，在保证分类精度的同时，降低了运行时间和计算复杂度，也达到了最高的适应度值，说明其在搜索空间中具有较强的探索和利用能力。此外，RNA 算法在大多数样本中获得了最小的标准差，表明其子结构能够增强分类的稳定性。因此，本文提出的融合算法在保证运行效率的前提下，既能保持较高的分类精度，又能有效地约简特征空间。

表 2-2 算法的参数设置

算法	参数
ReliefF	Proportion $\lambda = 0.5$
NOCSA	乌鸦的认知概率 $AP = 0.1$ 乌鸦的飞行长度 $fl = 2$
Ada-kNN	$k_{max} = 27$

表 2-3 所用算法和对比算法的平均分类准确率和标准差

算法	Acc (%)	STD
Only Ada-kNN	83.854	0.0301
ReliefF+ Ada-kNN	84.341	0.0213
ReliefF+ NOCSA+ Ada-kNN	83.883	0.0127

表 2-4 所用算法和对比算法特征个数、平均适应度和归一化运行时间

算法	特征数量	平均适应度	运行时间
Only Ada-kNN	33	0.5808	1
ReliefF+ Ada-kNN	17	0.3358	0.92
ReliefF+ NOCSA+ Ada-kNN	11	0.2624	0.89

2.4.4 特征选择算法对比实验

为了验证研究使用的算法的先进性，选择了过滤式特征选择算法和启发式特征选择算法中最经典和广泛的两种算法作为对比，即互信息法和遗传算法。表 2-5 展示了三种算法的分类准确率均值、标准差、特征数量和运行时间。三种对比算法的运行时间进行了归一化处理，并且以 RNA 算法的运行时间为单位。

表 2-5 RNA 算法和对比算法实验结果

算法	Acc (%)	标准差	特征数量	运行时间
互信息法	76.59	0.025	17	1.09
遗传算法	76.1	0.0626	15	1.03
RNA 算法	83.88	0.0127	11	1

实验结果表明,本文研究的 RNA 算法获得了最优的识别精度(83.88%),分别优于互信息法的 76.59%和遗传算法的 76.1%。RNA 算法排除了一多半相关性较差的特征,留下了 11 个有效的特征,因此在保证了分类准确率的前提下,在分类过程比其他算法减少了 3%-9%的运行时间,表明了其在搜索空间中具有强大的探索和利用能力。此外, RNA 算法因其排除了较多特征的影响,在重复分类实验中获得了最低的标准差值,表明该算法有更强的稳定性。综上所述,本文研究的 RNA 算法在保证运行快速性的前提下,不仅维持了较高的识别精度,还对特征有较强的约简能力。

图 2-3 中展示了三种算法的 F1 分数,实验结果显示, RNA 算法的 F1 分数为 0.81,而互信息法和遗传算法的 F1 分数分别为 0.75 和 0.74。这说明 RNA 算法在分类问题上具有明显的优势。




图 2-3 RNA 算法及对比算法的 F1 分数

2.4.5 分类器对比实验

在本研究中,我们结合了 ReliefF+NOCSA 结构,测试了数种在生物信号模式识别领域被广泛使用的分类算法以凸显 Ada-kNN 算法的优越性。我们把支持向量机 SVM 算法,传统 kNN 算法,机器学习算法 XBNet 和本研究中使用的 Ada-kNN 算法进行对比,图 2-4 显示了 4 个分类器对肌肉疲劳识别的 F1 分数。如图所示,与其他分类器相比,Ada-kNN 具有较高的模型质量,而 XBNet 的模型质量最低。




图 2-4 四种分类器肌肉疲劳识别的 F1 分数

表 2-6 中展示了四种算法的平均分类准确率及其标准差。结果表明，Ada-kNN 分类器获得了最高的平均分类准确率（83.883%），其余三种对比算法得到的准确率均低于 Ada-kNN 分类器。

表 2-6 所用分类器和对比分类器的平均分类准确率和标准差

算法	Acc (%)	STD
XBNet	67.548	0.0429
SVM	62.898	0.0519
kNN	73.344	0.0204
Ada-kNN	83.883	0.0127

此外，为了确保算法的快速性，对四种分类器运行时间进行了研究。四种算法的运行时间被归一化处理，并且将 Ada-kNN 算法的运行时间设置为单位时间。如表 2-7 所示，实验结果表明，Ada-kNN 的运行时间约为 34ms，SVM 和 XBNet 的运行时间均高于 Ada-kNN，而 kNN 是分类速度最快的分类器，比 Ada-kNN 分类器的运行时间减少了约 18%。但是 kNN 分类器的准确率比 Ada-kNN 分类器减少了约 10%，所以综合考虑 Ada-KNN 的分类器是兼顾准确率和快速性的最佳选择。

表 2-7 所用分类器和对比分类器的平均运行时间

算法	平均运行时间
XBNet	1.35
SVM	1.23
kNN	0.82
Ada-kNN	1

在图 2-5 至图 2-8 中,分别选取了一个数据样本,绘制了各个分类器分类结果的混淆矩阵。其中,横坐标代表测试集的标签,纵坐标代表预测的标签,绿色的方格即代表预测正确的结果,红色方格代表预测错误的结果。在最后一列中,绿色的数字代表真实类别被预测为该类别的比例。在最后一行中,绿色的数字代表真实类别被检测到的比例。由四张图可以分析得出,相比于其他对比模型,Ada-kNN 能够更好地识别出正确的类别,同时也能够更全面地覆盖所有的类别。




图 2-5 Ada-kNN 分类结果的混淆矩阵

1	54 29.5%	1 0.5%	6 3.3%	88.5% 11.5%
2	1 0.5%	50 27.3%	22 12.0%	68.5% 31.5%
3	0 0.0%	13 7.1%	36 19.7%	73.5% 26.5%
	98.2% 1.8%	78.1% 21.9%	56.2% 43.8%	76.5% 23.5%
	1	2	3	

图 2-6 kNN 分类结果的混淆矩阵

1	27 15.2%	0 0.0%	6 3.4%	81.8% 18.2%
2	0 0.0%	64 36.0%	26 14.6%	71.1% 28.9%
3	23 12.9%	0 0.0%	32 18.0%	58.2% 41.8%
	54.0% 46.0%	100% 0.0%	50.0% 50.0%	69.1% 30.9%
	1	2	3	

图 2-7 XBNet 分类结果的混淆矩阵




图 2-8 SVM 分类结果的混淆矩阵

2.4.6 与其他肌肉疲劳识别算法对比

在本研究中，通过选取准确率、分类数量和使用特征三个关键指标，我们对 RNA 算法与当前先进的肌肉疲劳识别算法进行了对比分析。表 2-8 展示了这些算法的性能对比，其中 RNA 算法表现出了其优势。

表 2-8 RNA 与其他肌肉疲劳识别算法对比

算法	准确率 (%)	分类数	使用特征
CNN-SVM ^[14]	80.33	2	RMS, iEMG, MF, MPF, BSE
FGNN ^[15]	94.3	2	RMS, iEMG, MNF 等 12 种时域和频域特征
TCN ^[16]	89	2	Mean, RMS, iEMG, ZC, ARV
MFFNet ^[17]	78.62	2	通过卷积神经网络提取特征
DEWOA-SVM ^[18]	85.5	2	RMS, MPF, IMNF, LZC 等 12 种时域、频域、时频域和非线性特征
LSTM ^[19]	95.18	2	RMS, iEMG, MF, MPF, PSD
CLT ^[20]	96.67	4	ApEn, PE
RNA	83.88	3	经过特征选择后的 11 种时域和频域特征

目前大多数研究中对肌肉疲劳的识别中所用到的特征方面存在两个问题：一是较为单一，不能更完整的利用表面肌电信号中蕴含的丰富的信息；二是部分方法采用神经网络提取表面肌电信号的时域和频域特征，可解释性不强。本文研究的 RNA 算法一定程度上解决了这两个问题。此外，目前对肌肉疲劳分类的研究多数仅停留在疲劳和不疲劳两类中，不能较好的反应肌肉的疲劳状态，与之相比，本研究加入的疲劳过渡态，可以对肌肉的疲劳状态进行预警，更有效的预防因肌肉疲劳造成的损伤。

综合对比表明，RNA 算法在特征选择和分类能力方面表现出色。与其他算法相比，RNA 算法在肌肉疲劳识别的准确率上具有竞争力，显示了其在肌肉疲劳识别领域的应用潜力。

2.5 本章总结

在本章节中，提出了一种综合特征选择与分类的 RNA 算法来构建肌肉疲劳识别模型。该 RNA 算法巧妙地结合了 ReliefF、NOCSA 和 Ada-kNN 三种算法，实现了各自优势的有机融合。ReliefF 算法承担了特征筛选的初步任务，为 NOCSA 算法的搜索过程设定了明确的方向，有效减少了启发式算法对初始条件的依赖。NOCSA 算法的加入显著提高了系统对噪声的鲁棒性，弥补了单独使用 ReliefF 时的敏感性。Ada-kNN 算法则精确评估了特征子集的分类效果。

进一步的对比实验和消融实验验证了 RNA 算法在特征筛选和识别准确率方面的优越性，证明了算法中各个组成部分的互补性，共同促成了出色的识别性能。相较于其他前沿算法，RNA 算法更加高效地利用了肌电信号中的信息。图 2-9 提供了 RNA 算法完整流程的清晰视图。




图 2-9 RNA 算法流程图

第3章 肌肉疲劳识别系统设计

3.1 系统整体需求分析

本研究的目标是设计并实现一套基于表面肌电信号的肌肉疲劳识别系统,该系统能够采集、处理、分析人体肌肉的表面肌电信号数据,并能够实时识别肌肉疲劳状态。基于对表面肌电信号产生机理、人体肌肉生理结构的深入分析,以及表面肌电信号在肌肉疲劳识别中的应用潜力,本研究在硬件系统和软件系统中提出了以下需求:

硬件需求:

(1) 电源需求: 为确保系统的供电稳定性并隔离电网干扰,本系统采用 USB 供电方式,无需额外屏蔽保护。

(2) 肌电信号采集需求: 系统需选择适宜的采集介质,实现差分输入方式采集表面肌电信号,并对信号进行必要的放大处理,以便于后续的信号处理。

(3) 模数转换需求: 将采集到的模拟信号转换为数字信号,以便于数字处理和分析。

软件需求:

(1) 信号传输功能需求: 通过串口通信实现肌电信号与肌电采集设置的双向传输,确保采集系统与上位机的有效连接。

(2) 患者信息建档功能需求: 记录并管理患者的基本信息(如编号、姓名、联系方式等),并将信息保存在本地数据库中。

(3) 肌电信号波形显示功能需求: 实时显示表面肌电信号波形,提供采集开始与停止的控制,并允许保存原始肌电信号数据。

(4) 肌电信号特征分析功能需求: 实时计算表面肌电信号的时域和频域特征,以反映信号的基本机理信息。

(5) 肌肉疲劳识别功能需求: 利用 ReliefF-NOCSA-AdaKNN 算法,根据表面肌电信号的时域和频域特征,实时识别肌肉疲劳状态。

以上需求分析为本研究设计的肌肉疲劳识别系统提供了明确的功能指导,确保系统的设计既符合实际应用需求,又具备必要的科学性和实用性。这些需求将指导后续的系统开发和实验验证工作。

3.2 系统整体方案设计

根据上文中的功能需求分析,本文设计的基于表面肌电信号的肌肉疲劳识别

系统总体设计方案如图所示。该套肌肉疲劳识别系统由表面肌电信号采集平台和肌肉疲劳识别上位机分析平台组成。表面肌电信号采集平台选择 STM32F103C8T6 作为主控芯片,选择 AD8236 和 AD8646 作为放大电路芯片,搭配 Ag-AgCl 表面电极,共同组成表面肌电信号采集系统。肌肉疲劳识别上位机分析平台选择 .NET framework 框架开发用于与用户交互的 UI 界面,选择 SQL server 数据库存储用户的基本信息,使用 MATLAB Compiler SDK 部署研究的肌肉疲劳识别算法在所需环境中,三者共同组成肌肉疲劳识别软件系统。

系统设计关注的问题可以分为以下几个部分来描述:

(1) 用于采集表面肌电信号的电极的选择。根据研究可知,选择合适的表面肌电电极可以用更便捷的方式采集到更高精度的表面肌电信号。本文将使用低阻抗,安全无毒的 Ag-AgCl 表面电极作为肌电信号采集的传感器。

(2) 主控系统的设计。设计一个基于 STM32 的 MCU 单片机系统,负责肌电信号和采集设置的处理与传输。

(3) 肌电采集模块设计。设计一个输入阻抗高,共模抑制比高,抗干扰能力强的前置放大电路,保证采集范围为 -5mV 至 $+5\text{mV}$,并且使用 STM32 的 AD 转换功能,把模拟信号转化为可供计算机识别的数字信号,以便对其进一步分析。

(4) 上位机软件功能设计。设计一套基于 .NET Framework 的软件系统。该系统可以实现以下功能:①使用 SQL Server 数据库对用户进行建档管理。②实时显示用户的原始表面肌电信号。③实时显示用户表面肌电信号的时域和频域特征。④搭载 RNA 算法,实时分析用户当前的肌肉疲劳水平。

系统整体结构如图 3-1 所示。




图 3-1 系统整体结构图

3.3 表面肌电信号采集平台设计

3.3.1 主控芯片选型和软件设计

本研究选择 STM32F103C8T6 作为主控芯片，主要基于其卓越的串行通信（USART）和模数转换（AD）功能。STM32F103C8T6 是意法半导体公司（ST）推出的一款基于 ARM Cortex-M3 内核的 32 位微控制器。其 USART 接口数量达到 3 个，支持多种串行通信协议，能够提供灵活的连接选项，适应多样化的数据交换需求。此外，该芯片具备高性能的 12 位模数转换器（ADC），最多可提供 16 个通道，转换速率高达 1 MBPS，确保了快速准确的模拟信号数字化处理。此外该芯片有着丰富的外设接口和高达 37 个 I/O 引脚，以及兼容 5V 信号的能力，为广泛的应用提供了强大的扩展性。综合考虑其性能参数和功能特性，STM32F103C8T6 是一种适合高性能、多功能系统集成的理想选择^[44]。本研究使用 STM32F103C8T6 最小系统开发板，其原理图如图 3-2 所示。




图 3-2 STM32F103C8T6 最小系统原理图

在本研究中，STM32 单片机的软件编程和编译工作是在 Keil μ Vision 软件（版本 V4.72）中完成的，采用 C 语言进行嵌入式软件的开发。STM32 单片机在系统中承担了以下关键功能：

（1）串口通信：利用外设 USART1，STM32 单片机与肌肉疲劳识别上位机分析平台进行数据交换。上位机软件接收用户指令，并通过串口通信将控制命令（如肌电信号的采集启停和采样率设置）发送至 STM32。当 STM32 接收到这些命令时，会触发串口中断事件，并按照既定的通信协议，将采集到的肌电信号数据传输回上位机。

（2）模数转换功能：STM32 内置的 A/D 转换器用于处理前置放大电路放大后的肌电信号电压幅值。该信号被引导至 STM32 的 ADC_IN 端口，并转换为数字信号，以便传输至上位机分析平台进行进一步的处理。

以上两点概述了 STM32 单片机在本系统中的主要软件功能，展示了其在肌

肉疲劳识别系统中的应用和重要性。这些功能的实现不仅确保了数据采集和传输的准确性，还提高了系统的整体效率和可靠性。

STM32 中软件流程图如图 3-3 所示。




图 3-3 STM32 中软件流程图

3.3.2 多级放大电路芯片选型和电路设计

据研究，人体表面肌电信号的幅值十分微弱，一般人的表面肌电信号幅值范围在 10 微伏到 5 毫伏之间，普遍为几百微伏，不超过 1 毫伏。并且表面肌电的输出阻抗比很高，容易受到共模干扰，因此需要设计合理的放大电路来确保高质量的表面肌电信号的采集。

本研究选用 AD8236 和 AD8646 芯片来构建放大电路。AD8236 是亚德诺半导体公司生产的低功耗仪表放大器，其特点包括极低的电源电流（最大 40 μA ），高输入阻抗（输入偏置电流 1pA，输入失调电流 0.5pA），以及优异的共模抑制比（110dB CMRR，增益为 100）。此外，AD8236 支持轨到轨输入和输出，增益可

通过单个电阻设定,工作电压范围广泛(1.8V至5.5V),适合于电池供电的应用场景^[45]。AD8236的芯片内部结构如图3-4所示。




图 3-4 AD8236 芯片原理图

AD8646 则是一款双通道轨到轨运算放大器,具备低失调电压(最大 2.5 mV),单电源供电(2.7 V至5.5 V),低噪声(8 nV/√Hz),宽带宽(24 MHz),高压摆率(11 V/μs),以及稳定的短路输出电流(120 mA)。AD8646 还通过了汽车应用认证,无反相,具有低输入偏置电流(1 pA)和低电源电流(每个放大器最大 2 mA),单位增益稳定。这些特性使 AD8646 成为滤波器、积分器、光电二极管放大器和高阻抗传感器等多种应用的理想选择,尤其适合于要求宽带宽和低失真的交流应用场景^[46]。AD8646 芯片引脚图如图 3-5 所示。




图 3-5 AD8646 芯片引脚图

AD8236 的增益可以通过更改电阻 R_G 的阻值设定,如公式(3-1)所示。

$$R_G = \frac{420k\Omega}{G - 5} \quad (3-1)$$

其中 G 为增益倍数。本设计使用 2.2kΩ 阻值的电阻,通过计算可知放大倍数约为 200 倍。

综上所述,AD8236 和 AD8646 的这些特性,使它们在放大电路设计中表现

出色，特别是在需要低功耗和高性能的应用中。因此，它们被选为本研究放大电路的核心组件。设计的多级前置放大电路原理图如图 3-6 所示：




图 3-6 多级放大电路原理图

3.3.3 表面电极的选择

本文采用 Ag-AgCl 凝胶电极作为表面肌电信号的传感器，将其贴在肱二头肌表面，与采集硬件相连。如图 3-7 所示，表面电极可分为凝胶电极、金属电极和新材料电极三类。凝胶电极由贴片、电极和导线组成，是目前最常用的表面肌电信号采集电极。凝胶电极能与皮肤紧密贴合，减少运动伪影，且可随肌肉弯曲，信号稳定，在表面肌电信号采集领域应用广泛^[47]。金属电极如拉普拉斯金属电极等，相比凝胶电极，需要更复杂的电路设计，且电极表面需光滑，使用区域受限，固定困难，因此在表面肌电信号采集中较少使用。新材料电极如基于纳米金颗粒的柔性电极等，具有可拉伸、灵敏度高等优点，但仍处于研究阶段，稳定性低、成本高，限制了其实际应用。



图 3-7 凝胶电极、金属电极和新材料电极

表面肌电信号采集平台实物图如图 3-8 所示。




图 3-8 表面肌电信号采集平台实物图

3.4 肌肉疲劳识别上位机分析平台设计

3.4.1 开发框架的选择

本文选用.NET Framework 作为上位机软件的开发框架，并使用其最新版本.NET Framework 4.8.1。.NET Framework 是由微软公司开发的一个软件框架，用于构建 Windows 操作系统上的应用程序。它提供了许多库和运行时环境，使得开发人员可以轻松地创建和部署各种类型的应用程序，如桌面应用程序、Web 应用程序、移动应用程序、游戏等。

.NET Framework 的优势在于其跨语言、跨平台、安全性高、易于维护、易于部署等特点。它支持多种编程语言，如 C#、VB.NET、F#等。.NET Framework 还提供了许多内置的库和工具，如 Windows Forms、WPF、ASP.NET、ADO.NET 等，使得开发人员可以快速构建各种类型的应用程序。此外，.NET Framework 还提供了许多安全性功能，如代码访问安全性、加密、身份验证等，使得开发人员可以轻松地创建安全的应用程序。

综上所述，.NET Framework 满足了本文软件系统所需的开发快速性、可扩展性和高安全性的要求，故使用该框架开发肌肉疲劳识别软件系统。

3.4.2 串口通信协议设计

串口通信协议是一种规定了数据传输格式、速率、校验和控制等方面的标准，它使得不同的设备可以方便地连接起来进行通讯。在本项目中，串口通信协议可以提高数据传输的效率和可靠性，通过合理的数据结构、波特率、奇偶校验和停止位等设置，可以减少数据的冗余和错误，提高传输的速度和准确性。也可以实

现表面肌电信号原始数据的分包和重组,便于传输和处理,同时可以保证数据的完整性和一致性。综上所述,设计串口通信协议的必要性是显而易见的,它可以使得串口通信更加高效、可靠、安全和灵活,满足不同的通信需求和场景。因此,本系统中根据需求,参考 Modbus 协议设计若干通信协议,用于肌电采集设备和上位机软件的通信^[48]。

在本研究中,通信协议的设计关键在于确保数据包的结构和传输的可靠性。如表 3-1 和表 3-2 所示,肌电采集设备的启停控制请求由上位机发出,并传输至肌电采集设备。为了增强传输过程的稳定性,肌电采集设备在接收到上位机的指令后,将原始请求包回传作为响应,从而实现双向验证。数据包的完整性通过采用 CRC-16 校验码来保证。

表 3-1 肌电采集停止控制功能请求数据包结构

数据头		数据	数据尾	
数据帧头	功能码	采样频率设置	校验码	数据帧尾
0xFF	0x01	1byte	2byte	0x0D 0x0A

表 3-2 肌电采集开始控制功能请求数据包结构

数据头		数据	数据尾	
数据帧头	功能码	采样频率设置	校验码	数据帧尾
0xFF	0x02	1byte	2byte	0x0D 0x0A

采样频率的选择性提供了系统的灵活性,用户可根据需求选择 500Hz(对应 0x01)、1000Hz(对应 0x02)或 2000Hz(对应 0x03)的采样率。系统默认设置为 2000Hz,以满足高精度采样的需求。表 3-3 详细描述了肌电信号的数据包结构,其中每 200 个肌电数据点被编码并打包成一个 400 字节的数据包,每个数据点占用 2 字节。此外,为了降低下位机的计算负担并验证数据的准确性,采用了奇偶校验码进行校验。这种设计不仅优化了数据传输的效率,还提高了系统的可靠性和稳定性。

表 3-3 肌电原始信号传输数据包结构

数据头		数据	数据尾	
数据帧头	功能码	肌电原始数据	校验码	数据帧尾
0xFF	0x03	400byte	2byte	0x0D 0x0A

此外,上下位机串口通信的波特率选择为 115200。

3.4.3 波形显示模块设计

本模块的设计核心在于实现肌电信号的实时可视化,同时优化内存使用。在上位机软件成功接收肌电采集模块所采集的原始数据后,系统将数据存入一个固

定长度为 5000 的队列缓冲区。此队列不仅作为数据的临时存储结构，而且通过与 Chart 控件的绑定，实现了肌电信号的动态折线图显示。这种方法不仅为用户提供了一个直观的界面来观察和分析肌电信号的特征及其变化，而且通过限制队列长度，有效地管理了内存占用，保证了系统的响应速度和稳定性。

为了进一步增强系统的实用性，原始肌电数据还通过 System.IO.File 类的相关方法输出到文件中。这一步骤不仅为用户提供了数据的备份，还便于用户在软件外部进行更深入的分析或研究。文件写入操作采用了高效的 I/O 策略，确保了数据的完整性和写入速度。

综上所述，波形显示模块的设计充分考虑了用户体验和系统性能，通过精心的数据结构选择和高效的编程实践，实现了肌电信号的实时可视化和数据管理的双重目标。这一设计不仅提高了数据处理的效率，而且为肌肉疲劳状态的监测和分析提供了强有力的工具。

3.4.4 疲劳分析模块设计

在本研究中，肌肉疲劳识别模型的构建和部署过程体现了对精确性和效率的追求。第二章详细介绍了在 MATLAB R2023a 平台上构建的模型，并将其封装为两个关键函数：

```
function [feature] = feature_extraction(signal)
```

此函数负责处理肌电信号，从中提取关键特征，以便于后续的软件展示和肌肉疲劳状态分类。输入参数 signal 为 400×1 的 MWArray 类型数组，代表原始肌电信号。输出 feature 为 11×1 的 MWArray 类型数组，包含经筛选的肌电信号特征。

```
function [fatigue] = fatigue_recognition(feature)
```

该函数用于识别肌肉疲劳状态。输入参数 feature 为前一函数输出的肌电信号特征数据。输出 fatigue 为 1×1 的 MWArray 类型数据，其中 0、1、2 分别代表轻松态、疲劳过渡态和疲劳态。疲劳状态的数字化标签便于数据处理和结果的可视化展示，如折线图形式在 Chart 控件中呈现，使用户能直观监测肌肉疲劳状态的变化。

为了将这些函数部署至 .NET Framework 平台，采用了 MATLAB Compiler SDK 进行代码转换。部署流程如下：

(1) 在 MATLAB 命令行窗口输入 deploytool 命令，启动“Library Compiler”工具，以便将 MATLAB 函数打包以供其他平台使用。

(2) 在“Library Compiler”中，选择“.NET Assembly”作为输出类型，确保生成的.dll 文件兼容 .NET Framework 平台。在“EXPORTED FUNCTIONS”中

选定 `feature_extraction` 和 `fatigue_recognition` 函数，并执行打包操作。完成后，生成 `fatigue_recognition.dll` 文件。

(3) 在 Visual Studio 中，通过引用管理器添加对生成的 `.dll` 文件的引用。同时，为了处理 MATLAB 数据类型，还需引用 `MWArray.dll`。

(4) 由于导出的 MATLAB 函数仅支持 64 位系统环境，因此在 Visual Studio 的配置管理器中将解决方案平台设置为 x64。

以下代码示例展示了如何在 .NET Framework 环境中调用 MATLAB 导出的函数及其数据处理所需的 `MWArray` 数据类型：

```
using MathWorks.MATLAB.NET.Arrays;  
using fatigue_recognition;
```

以上步骤确保了肌肉疲劳识别模型的准确部署和高效运行，为本研究提供了坚实的技术支持。

3.4.5 用户数据库设计

本研究采用了 SQL Server，一种由微软公司开发的先进关系型数据库管理系统 (RDBMS)，以实现用户数据的高效和可靠存储。SQL Server 2019 的引入，特别是其在企业级应用程序和数据仓库中的广泛应用，为本研究提供了一个强大的数据管理平台。该系统与 Windows 操作系统和 .NET 框架的高度兼容性，为基于 Windows 平台的应用程序开发和部署提供了便利^[50]。

为了有效地管理用户信息并记录其使用情况，我们设计了一个用户数据库，该数据库利用 SQL Server 2019 的强大功能，确保了数据的安全性和完整性。数据库结构如表 3-1 所示，包括以下字段：

(1) 用户序号：作为主键，为每个用户分配一个唯一标识符，确保用户数据的唯一性和可追溯性。

(2) 姓名：记录用户的个人姓名信息，用于身份确认和联系。

(3) 电话号码：存储用户的联系电话，便于进行必要的通信。

(4) 最后使用时间：记录用户最近一次使用肌肉疲劳识别系统的时间戳，这对于分析用户的使用模式和频率具有重要意义。

表 3-1 用户数据库结构

列名	数据类型	示例
序号	int	1
姓名	nchar (10)	张三
电话	varchar (50)	17777777777
最后使用时间	datetime	2024-01-03 14:30:00

用户数据库支持通过上位机软件界面进行数据的增删改查操作,提高了用户管理的效率和灵活性。此外,数据库设计还考虑了数据的安全性和隐私保护,确保了用户信息的保密性。通过这种设计,用户数据库不仅能够满足当前的数据管理需求,还具备了良好的扩展性和维护性,为未来可能的系统升级和功能扩展提供了基础。

3.4.6 软件界面设计

在本研究中,肌肉疲劳识别上位机软件的界面设计采用了模块化方法,以提高用户交互的效率和直观性。软件界面包括以下关键模块:

(1) 串口连接模块: 此模块负责建立与肌电采集设备之间的通信连接,确保数据传输的稳定性和可靠性。

(2) 用户管理模块: 该模块允许操作者创建和管理用户配置文件,从而个性化地跟踪和分析每个用户的肌肉疲劳数据。

(3) 设置模块: 此部分提供了一系列参数设置选项,使研究人员能够根据实验需求调整设备配置。

(4) 波形显示模块: 它实时展示肌电信号的波形,为用户提供了即时的生物反馈。

(5) 疲劳状态展示: 该模块以图形化的方式展现用户的肌肉疲劳状态,增强了数据的可读性和易理解性。

(6) 特征展示模块: 从肌电信号中提取的特征以表格的形式展现,辅助研究人员快速识别关键的生物标志。

(7) 启停控制模块: 提供了开始和停止肌电信号采集的功能,增加了操作的灵活性。

每个模块都经过精心设计,以确保用户能够轻松地访问和操作软件,同时保持界面的整洁和功能的直观。软件界面的设计旨在优化用户体验,同时提供强大的功能性,以支持复杂的数据分析和处理。图 3-9 详细展示了软件界面的布局和各模块的交互方式。




图 3-9 肌肉疲劳识别上位机分析平台界面设计图

在本研究中,肌肉疲劳识别上位机软件的设计精心构建了两个核心流程:数据接收处理流程和用户信息查询流程。这两个流程共同构成了软件的基础架构,确保了系统的高效运行和用户数据的准确管理。

数据接收处理流程:该流程是系统的数据处理核心,负责接收来自采集平台的肌电信号数据。流程首先展示原始信号波形,为用户提供直观的数据视图。随后,系统计算信号的关键时域和频域特征,这些特征是识别肌肉疲劳程度的基础。最终,软件应用先进的算法对这些特征进行分析,实现肌肉疲劳状态的准确识别。

用户信息查询流程:此流程致力于用户数据的有效管理,允许用户查询和更新使用信息。通过这一流程,系统管理员能够监控和维护用户档案,确保信息的时效性和准确性。整体软件流程如图 3-10 所示。




图 3-10 肌肉疲劳识别上位机分析平台软件流程图

3.5 本章总结

在本章节中，我们详细阐述了基于实际功能需求所设计的肌肉疲劳识别软硬件系统及其具体实现过程。系统由两大组成部分构成：肌电信号采集平台和肌肉疲劳识别上位机分析软件。采集平台负责以预定的采样频率收集肌肉表面的肌电信号，并将数据实时传输至上位机。上位机软件则采用了本文研究的 RNA 算法，对肌电信号进行实时分析和处理。

为了适应实际应用需求，上位机软件进一步集成了用户管理系统和原始肌电信号导出功能，从而增强了系统的应用范围并提升了其实用性。这些功能的添加不仅优化了用户体验，还为系统的广泛应用提供了坚实的基础。总体而言，本章节的设计思路和实施策略确保了系统的高效性和可靠性，为肌肉疲劳状态的准确识别奠定了坚实的基础。

第4章 肌肉疲劳识别实验与系统测试

4.1 表面肌电信号采集及分析

4.1.1 实验设备

本实验使用上文中设计的硬件设备对表面肌电信号进行采集。实验使用 PC 的 CPU 为 AMD R5-5600H, GPU 为 Nvidia GTX 1650, RAM 为 16GB。该 PC 与上文设计的肌电采集设备进行连接,用来处理采集到的肌电信号,并运行研究所用的算法。研究所使用的全部算法均运行在 Matlab R2023a 和 Python 3.11 的环境中。除此之外,实验使用到的器材还有磨砂膏、75%医用酒精、刮毛刀、6kg 哑铃和 Ag-AgCl 采集电极等。

4.1.2 方案设计

表面肌电信号 (Surface Electromyography, sEMG) 是记录人体肌肉活动的一种无创技术,它反映了肌肉细胞的电生理特性和功能状态,其幅值和频率与肌肉的收缩强度和速度有关,因此可以用来评估肌肉的力量和疲劳程度,以及神经肌肉系统的功能和病理状态。

表面肌电信号的产生机理可以分为以下三个步骤^[5]:

(1) 肌肉细胞受到中枢神经系统或外界刺激,产生动作电位 (IAP), 导致肌肉收缩。

(2) 动作电位沿着肌纤维传播,形成肌纤维动作电位 (SEAP), 进而形成运动单元动作电位 (MUAP)。

(3) 运动单元动作电位在人体组织中产生电流场,通过表皮层传递到皮肤表面,形成表面肌电信号。

表面肌电信号的传递过程和形成过程如图 4-1 所示。




图 4-1 表面肌电信号的产生过程和形成过程

肌肉疲劳研究主要关注受自主意识控制的骨骼肌组织，而肱二头肌是人体最经典的一块骨骼肌，因此本文把肱二头肌作为研究对象。肱二头肌是位于上臂前侧的一种骨骼肌。肱二头肌属于多头肌肉，起点分为长头和短头，因此得名。肱二头肌起于肩胛骨的两个部位，止于桡骨的粗隆和前臂的筋膜，整体形状呈梭形。肱二头肌的主要功能是屈肘、屈肩和旋外前臂。肱二头肌的训练方法有多种，包括杠铃弯举、哑铃弯举、斜板弯举等。

电极的放置会影响采集到的信号，因为肌肉收缩产生的电活动取决于电极相对于肌肉的位置。同时，还要注意将电极放置在能够最大程度减少与其他邻近肌肉信号的串扰的位置，从而获得可靠和稳定的表面电极信号。神经末梢和肌肉连接的区域被称之为支配区（Innervation Zone, IZ）。研究表明，电极放置在肌肉支配区上会影响肌电信号的采集。电极放置一般有两种方法，分别是沿着肌肉的长轴纵向放置和横向放置。对于纵向放置，双极电极一般放置在距离远端运动终板区一半的位置，并靠近肌肉中线和远端肌腱。这种放置位置远离了肌肉的支配区，而且传感器在运动时不会覆盖肌腱，从而避免了。对于横向放置的，双极电极应该放置在与肌肉长轴平行的中点处，并避开肌肉记录区的边界^[51]。根据以上研究，确定了肱二头肌的电极放置位置。肱二头肌结构示意图和电极放置位置如图 4-2 所示。其中红色电位和绿色电位为采集电极放置点位，黄色点位为参考电极放置点位。




图 4-2 肱二头肌结构和电极放置位置示意图

4.1.3 实验流程

本研究旨在通过测量人体右手臂肱二头肌在举哑铃时的肌电信号，实时识别肌肉疲劳状态，获取多样化的肌电信号数据。为此，本研究招募了 10 位受试者，其中 8 位男性和 2 位女性，平均年龄为 23.5 岁，平均身高为 174.2cm，平均体重为 67kg，受试者的具体信息如表 4-1 所示。

表 4-1 实验对象信息

参与者	性别	年龄	体重/kg	身高/cm	BMI	分类
参与者 1	男	23	63	170	21.8	正常
参与者 2	男	23	75	178	23.7	正常
参与者 3	男	24	87	175	28.4	肥胖
参与者 4	男	26	88	185	25.7	偏重
参与者 5	女	22	45	157	18.3	偏瘦
参与者 6	男	25	73	180	22.5	正常
参与者 7	女	23	50	166	18.1	偏瘦
参与者 8	男	22	67	180	20.7	正常
参与者 9	男	23	75	177	23.9	正常
参与者 10	男	24	47	174	15.5	偏瘦

受试者均为右手使用者，无心血管疾病和神经肌肉骨骼疾病，身体状况良好，部分参与者有一定的训练基础。受试者在实验前均被告知研究的目的、方法和潜在风险，并签署了知情同意书。此外，受试者被要求在测试前 24 小时内避免高

强度运动，保持清淡且健康的饮食，不要熬夜，避免摄入咖啡因、尼古丁等兴奋剂或酒精。

本研究采用 RPE 分数作为肌肉疲劳程度的划分依据，RPE 是一种主观疲劳等级量表，由受试者根据自身主观疲劳感受主动报告。本研究使用的 RPE 分数及其对应的疲劳等级如表 4-2 所示。其中，RPE 分数 6-10 为轻松态，11-18 为疲劳过渡态，19-20 为疲劳态。

表 4-2 RPE 等级划分表

等级	自我感受	疲劳状态
6	没有压力，放松	轻松态
7	极度轻松	
8		
9	非常轻松	
10		
11	轻松	疲劳过渡态
12		
13	有些吃力	
14		
15	吃力	
16		
17	非常吃力	
18		
19	极度吃力	疲劳态
20	尽最大努力	

实验前，操作员对受试者进行 Borg 主观疲劳等级量表的指导，帮助其熟悉量表的使用，并根据个人情况进行若干次预实验，使受试者熟悉实验过程。每位受试者在测试前在凳子上静坐 2-3 分钟，达到最佳身心放松状态。实验过程中，首先用刮毛刀对皮肤进行清洁和脱毛处理，并用磨砂膏和 75% 的医用酒精清洁皮肤表面，这样做是减少皮肤阻抗的干扰，增加皮肤的导电性，尽可能降低环境因素对采集信号的影响。然后，根据上文的分析和相关医师的帮助，确定了肱二头肌的具体位置和肌纤维的大致方向，将表面肌电传感器的两个差分电极按照中心间隔 2cm 的距离贴合在肱二头肌突起的最高位置，参考电极贴合在肘部骨骼处，尽量远离测试肌肉。受试者正坐于椅子上，颈部、背部挺直，躯干与大腿，大腿与小腿分别保持垂直，左手平放在左腿上，右前臂与右上臂保持垂直，略微靠近躯干。部分实验者的电极贴合位置和采集数据过程如图 4-3 所示。




图 4-3 信号采集实验过程图

实验开始后,把哑铃放于受试者手中,保持上述姿势,采集负重状态下的肌电数据。采集过程中,受试者保持恒力托举哑铃,操作员记录受试者的 RPE 值和相应时间,并观察受试者的右臂关节角度、抖动状况和主观感受。当受试者的右前臂与右上臂无法保持 90° 或右臂剧烈颤抖时结束数据采集。重复以上操作,直至 10 名受试者数据全部采集完成。采集时间和疲劳时间因人而异,操作员在一旁给予适当的语言鼓励,使受试者尽可能保持 50s 以上的负重状态数据采集 [15]。

10 位实验者采集到的部分肌电信号原始数据如图 4-4 所示,纵轴代表肌电信号值,单位为 μV 。




图 4-4 10 位实验者的部分肌电信号原始数据

4.1.4 特征分析

在肌肉疲劳分析中，常用的 sEMG 时域和频域特征包括均方根值（RMS）、积分肌电值（iEMG）和中值频率（MF）等。根据研究，随着肌肉疲劳的加重，RMS 和 iEMG 的值会增加，MF 的值会减小^[52]。为了研究信号特征变化的规律，本节以一位年龄为 23 岁，BMI 为 21.8 的正常体型男性实验者的 sEMG 信号为例，记录了实验者的肱二头肌从不疲劳到疲劳的发展进程。为了排除实验开始和结束的干扰，我们分别去除了 sEMG 信号开头一秒和结束一秒，并把剩下的 sEMG 信号按照上文中确定的滑动窗口分割方案进行数据分割。为了对这些特征的变化有更为直观的表现，我们对特征值进行了线性回归^[52]。实验结果绘制为折线图，图中横轴为时间，蓝色折线是对应的特征值，绿色是对特征数据进行线性回归的拟合结果。

随着疲劳的加重，sEMG 信号的 RMS 和 iEMG 特征呈现出增加的趋势，其中 RMS 拟合出的斜率为 19.92，iEMG 拟合出的斜率为 308.79，分别如图 4-5 和图 4-6 所示。sEMG 信号的 MF 特征呈现出下降的趋势，拟合出的斜率为-0.21，如图 4-7 所示。




图 4-5 受试者肌电信号 RMS 特征变化图




图 4-6 受试者肌电信号 iEMG 特征变化图




图 4-7 受试者肌电信号 MF 特征变化图

4.2 肌肉疲劳识别系统测试

4.2.1 肌肉疲劳识别功能测试

本研究的肌肉疲劳识别功能测试部分展示了上位机分析平台实际运行时的软件界面。用户在连接肌电信号采集硬件设备后，通过点击“开始测量”按钮启动了肌电信号的数据采集过程。采集得到的数据实时呈现在界面上方的折线图中，为用户提供了直观的信号展示。系统进一步实时计算并展示了肌电信号的经典时域和频域特征，这些特征在表格中得以详细呈现。




图 4-8 肌肉疲劳识别上位机分析平台运行界面

在特征计算完成后，本系统利用先前研究的 RNA 算法对肌电信号进行了实时识别和分类。分类结果通过折线图形式在软件界面中展示，使得分析结果一目了然。测试结果表明，肌肉疲劳识别功能的核心要求已在系统中得到了实现，并且系统运行表现稳定。这一部分的测试验证了系统设计的完整性和实用性，为后续的应用提供了坚实的基础。

4.2.2 肌电信号存储功能测试

在软件界面的设置界面中提供了肌电信号写入文件选项，用户可通过此选项激活该功能。启用后，系统将肌电信号以纯文本格式存储至文件中，确保数据的完整性和可读性。文件命名遵循“姓名_采集时间_采样率.txt”的格式，这一命名约定有助于用户快速识别和管理数据文件。

通过这种方式，系统提供了一种高效且结构化的方法来保存肌电信号数据，便于用户进行后续的数据分析和研究工作。此功能的测试验证了系统在数据管理方面的可靠性和用户友好性。

4.2.3 用户管理功能测试

为了提升用户管理的效率和精确性，本系统集成了一个先进的用户管理功能。通过软件界面的“用户管理”模块，用户可以轻松访问用户选择界面。在该界面

中, 仅需输入用户编号, 系统便能自动检索数据库, 快速准确地显示出用户的姓名和电话信息。此外, 系统还支持输入新的用户信息, 包括姓名和电话, 以创建新的用户档案, 并为其自动分配独一无二的用户编号。这一功能不仅简化了用户数据的录入过程, 还优化了用户信息的存储和检索流程, 极大地提升了用户管理的便捷性和系统的整体性能。

在 Microsoft SQL Server Management Studio 中, 可以查看当前所存储的所有用户信息, 如图 4-9 所示。

ID	name	time	tel
1	张三	2023-02-24 21:52:51.000	1777777777
2	李四	2022-12-17 11:35:08.000	18888888888
3	王五	2023-03-01 17:46:37.000	12345678901
4	吉田种树	2023-01-12 21:11:28.000	15555555555

图 4-9 存储的用户信息

4.2.4 实际应用测试

为了验证该系统的有效性和实用性, 本文结合实际应用场景对设计的系统进行使用。

拳击是一种综合格斗运动项目, 而肱二头肌对于拳击中的一些动作和技巧至关重要。肱二头肌在拳击中不负责产生力量, 而是将身体的能量传送到拳头中, 肱二头肌的耐力对于持续的出拳也至关重要。此外, 摆拳和上勾拳的速度和爆发力中起到关键作用。因此练习拳击可以有效训练人体肱二头肌。高强度的拳击训练会造成许多运动损伤, 乳酸等代谢产物会在肌肉中积累, 导致肌肉产生酸痛和疲劳感。连续的运动也会使导致神经疲劳, 丧失水分, 从而影响运动员的速度、力量和持续性, 造成肌肉疲劳的问题^[53]。

本研究使用《有氧拳击》作为指导, 研究拳击过程中的肌肉疲劳变化。《有氧拳击》是 Imagineer 株式会社和 Jupiter 株式会社共同制作的, 由任天堂发行至 Nintendo Switch 上的一款体感健身游戏。游戏中有虚拟教练指导玩家进行拳击动作的训练, 从而达到锻炼肌肉、提高心肺功能的效果。

在实际运动前, 按照上文中提到的实验步骤把肌电信号采集电极安装在实验者右臂肱二头肌处, 并让实验者进行充分的热身训练以防止运动损伤。按照游戏给出的训练计划, 本次训练包含五组训练, 分别是拉伸、下潜躲避组合、上勾拳组合、初阶动作组合和直拳组合, 每组训练的时间和预计消耗热量如表 4-3 所示, 其中预计消耗热量越高说明该组训练运动强度越大。每组训练包含直拳、刺拳、勾拳和上勾拳等拳击动作。

表 4-3 拳击训练预计时间和消耗热量

训练	时间/min	预计消耗热量/kcal
拉伸	3	10
下潜躲避组合	6	68
上勾拳组合	12	123
初阶动作组合	8	105
直拳组合	6	58

运动过程中，左臂的肱二头肌按照上文的方法粘贴电极，并连接在肌肉疲劳识别系统中，以监控肱二头肌的疲劳程度，实验过程如图 4-10 所示。在进行前三组训练时，受试者的主观感受较为轻松，系统对肱二头肌疲劳状态的评价为轻松态。在第四组训练后，受试者报告肌肉酸痛，系统对肱二头肌疲劳状态的评价为疲劳过渡态，此时肌电波形和特征如图 4-11 所示。具体表现为肌肉的均方根值和积分肌电值相较于非疲劳状态有所上升，而平均频率和中值频率则呈下降趋势。基于这些数据，为预防潜在的肌肉损伤，实验被终止，随后受试者进行了拉伸训练以促进肌肉放松。



图 4-10 拳击训练过程




图 4-11 肌肉疲劳状态下肌电波形及特征

通过在拳击场景下的实际应用测试可以得出,本文所提出的系统实际运行良好、功能完备,可以有效地对运动中的年轻人进行预警,从而达到保护年轻人的作用,具有较强的实用价值。

4.3 本章小结

本章节对论文开发的肌肉疲劳识别系统进行了详尽的实验验证。首先,通过设计一系列表面肌电信号(sEMG)采集实验,我们利用抬举哑铃的动作收集了不同疲劳状态下的肌电信号数据。这些数据为后续的分析 and 模型构建提供了基础。

接着,我们对所构建的肌肉疲劳识别系统进行了全面的功能测试。测试结果证实了系统的各个组成模块均能正常运作,系统整体功能完善。此外,为了评估系统的实际应用效果,我们选择了拳击这一具有高肌肉疲劳风险的运动场景进行了实用性测试。测试结果显示,系统能够有效预警潜在的运动损伤,从而为保障运动员的身体健康提供了有力的技术支持。

综上所述,本章节不仅验证了肌肉疲劳识别系统的理论设计和功能实现,还通过实际应用场景的测试,展示了系统在运动健康管理中的潜在价值和实用性。这些成果为未来在运动科学领域的研究和应用提供了坚实的基础。

第5章 总结与展望

5.1 总结

本研究致力于开发一种精确的肌肉疲劳状态分类方法,并将其应用于基于表面肌电信号(sEMG)的肌肉疲劳识别系统设计中。通过基于个体疲劳主观感受的sEMG信号采集实验,本研究确保了所采集数据的准确性,能够真实反映肌肉疲劳状态。在特征提取阶段,本研究在时域和频域提取了大量信号特征,并通过文献支持,分析了肌肉疲劳程度增加时,肌电信号参数特征的一致变化趋势。这些变化包括肌肉疲劳的发展伴随着积分肌电值(iEMG)和均方根值(RMS)的增加,以及中值频率(MF)的降低。

为了消除干扰特征对分类效果的影响,本研究提出了一种创新的RNA算法,结合了ReliefF、NOCSA和Ada-kNN三种算法的优势。通过消融实验,本研究验证了RNA算法的有效性,其中ReliefF子结构将原始特征集约简了50%,有效排除了大量干扰特征。ReliefF和NOCSA的结合进一步减少了特征数量,而对分类精度的影响微乎其微,从而提高了分类器的运行效率,更适合实际应用。适当的特征缩减不仅提高了平均分类准确率,还降低了分类准确率的标准差,使分类结果更加稳定。总体而言,RNA算法有效减少了特征数量,同时保持了较高的平均分类准确率,并实现了更稳定的分类效果。

在分类器选择方面,本研究采用了改进的kNN算法Ada-kNN。与传统kNN算法相比,Ada-kNN解决了超参数优化和类别不平衡问题。通过对比实验,本研究展示了Ada-kNN的优越性,其分类准确率分别比kNN、支持向量机(SVM)和先进的机器学习算法XBNet高出10.53%、20.99%和16.34%。

本研究还特别设计了基于个体疲劳主观感受的sEMG信号采集实验,通过模拟不同程度的肌肉疲劳状态,更准确地评估了使用的算法的性能。

综上所述,本研究的融合算法在肌肉疲劳识别领域的贡献如下:首先,使用不同受试者数据构建的模型训练和测试集有效预防了过拟合问题;其次,通过准确率、F1得分等多维度评价指标,实现了稳定且准确的肌电信号疲劳识别;第三,特征提取融合算法充分发挥了不同特征提取器的优势,提升了模型的整体性能。

此外,本研究设计了一套肌肉疲劳识别软硬件系统,集成了RNA算法,以便于实际应用。系统的硬件部分以STM32F103C8T6为主控芯片,通过多级放大电路增强了采集到的sEMG信号,并通过串口将数字化数据传输至上位机软件。

上位机软件负责提取肌电信号特征，并利用 RNA 算法进行特征筛选和肌肉疲劳识别。该系统在拳击训练场景中的应用验证了其实用性。

肌肉疲劳增加了运动中受伤的风险，因此，相关研究一直是生物医学和运动科学领域的焦点。基于表面肌电信号的肌肉疲劳识别技术，以其便利性和准确性，为广泛应用提供了基础，在康复训练和运动训练等领域具有重要价值。

5.2 未来研究展望

本研究虽已取得初步成果，但在肌肉疲劳识别领域，仍有广阔的研究空间。未来研究的展望如下：

（1）表面肌电信号的纯净采集。运动过程中的出汗等生理活动会对表面肌电信号的质量产生影响，未来研究需致力于开发更高效的信号采集技术，以减少这些生理因素的干扰，从而提高信号的纯净度和可靠性。

（2）信号降噪与滤波算法的优化。表面肌电信号的采集不可避免地会受到外界电磁干扰，因此，研究更先进的降噪和滤波算法，以提取更精确的肌电信号信息，是未来工作的重要方向。

（3）脑电与肌电信号的联合分析。鉴于肌肉疲劳与中枢神经系统的密切关联，未来研究可以探索脑电信号与肌电信号的结合，以预测肌肉疲劳。这种多模态分析方法有望提高识别率，并为理解肌肉疲劳的神经机制提供新的视角。

参考文献

- [1] Schwiete C, Roth C, Skutschik C. Effects of muscle fatigue on exercise-induced hamstring muscle damage: a three-armed randomized controlled trial[J]. European Journal of Applied Physiology, 2023: 1-17.
- [2] Enoka R M. Mechanisms of muscle fatigue: central factors and task dependency[J]. Journal of Electromyography and Kinesiology, 1995, 5(3): 141-149.
- [3] Dos Santos R M, e Costa F C, Saraiva T S. Muscle fatigue in participants of indoor cycling[J]. Muscles, ligaments and tendons journal, 2017, 7(1): 173.
- [4] Beaver W L, Wasserman K, Whipp B J. A new method for detecting anaerobic threshold by gas exchange[J]. Journal of Applied Physiology, 1986, 60(6):2020-7.
- [5] Al-Mulla M R, Sepulveda F, Colley M. A review of non-invasive techniques to detect and predict localised muscle fatigue[J]. Sensors, 2011, 11(4): 3545-3594.
- [6] Kimura T, Hamada T, Watanabe T. Mechanomyographic responses in human biceps brachii and soleus during sustained isometric contraction[J]. European journal of applied physiology, 2004, 92(4-5): 533-539.
- [7] Sometti D, Semeia L, Baek S. Muscle fatigue revisited—insights from optically pumped magnetometers[J]. Frontiers in physiology, 2021, 12: 724755.
- [8] Qu M, Zhou J, Lv D. Continuously monitoring of muscle fatigue based on a wearable micromachined ultrasonic transducer probe[J]. Sensors and Actuators A: Physical, 2024, 365: 114892.
- [9] 张鄂,王冠华,李岳. 基于 NIRS 的局部肌肉疲劳与脑疲劳及人体舒适性实验[J]. 四川兵工学报,2012,33(11):120-123.
- [10] Yang J Y, Zhuang J R, Wu G Y. Study of current emotion and muscle fatigue evaluation method for a walking assistive device[C]//2020 IEEE/ASME International Conference on Advanced Intelligent Mechatronics (AIM). IEEE, 2020: 1884-1889.
- [11] Kwatny E, Thomas D H, Kwatny H G. An application of signal processing techniques to the study of myoelectric signals[J]. IEEE Trans Neural Syst Rehabil Eng; 1970, 19(5): 578-587.

- [12] 易灿南, 唐范, 左华丽. 基于 sEMG 的拉物行走作业肌肉疲劳发展机理研究[J]. 人类工效学, 2022, 28(1): 37-42.
- [13] Qassim H M, Hasan W Z W, Ramli H R. Proposed fatigue index for the objective detection of muscle fatigue using surface electromyography and a double-step binary classifier[J]. Sensors, 2022, 22(5): 1900.
- [14] Wang J, Sun Y, Sun S. Recognition of muscle fatigue status based on improved wavelet threshold and CNN-SVM[J]. IEEE Access, 2020, 8: 207914-207922.
- [15] Liu G, Xu L, Xiao R. Muscle Fatigue Classification Method of sEMG Signal Based on FGNN Algorithm[J]. Science Technology & Engineering, 2022, 22(19): 8370-8377.
- [16] Mu D, Li F, Yu L. Study on exercise muscle fatigue based on sEMG and ECG data fusion and temporal convolutional network[J]. Plos one, 2022, 17(12): e0276921.
- [17] Zhang Y, Chen S, Cao W. MFFNet: Multi-dimensional Feature Fusion Network based on attention mechanism for sEMG analysis to detect muscle fatigue[J]. Expert Systems with Applications, 2021, 185: 115639.
- [18] Liu Q, Liu Y, Zhang C. sEMG-based dynamic muscle fatigue classification using SVM with improved whale optimization algorithm[J]. IEEE Internet of Things Journal, 2021, 8(23): 16835-16844.
- [19] Wang J, Sun S, Sun Y. A muscle fatigue classification model based on LSTM and improved wavelet packet threshold[J]. Sensors, 2021, 21(19): 6369.
- [20] Liu J, Tao Q, Wu B. Dynamic muscle fatigue state recognition based on deep learning fusion model[J]. IEEE Access, 2023, 11: 95079-95091.
- [21] Nakashima K, Isomoto K, Kushida D. Estimation model of muscle fatigue based on muscle fiber type using electromyography[J]. Electronics and Communications in Japan, 2021, 104(1): 37-46.
- [22] González-Zamora P, Benitez V H, Pacheco J. A feature-based processing framework for real-time implementation of muscle fatigue measurement[J]. Cluster Computing, 2023, 26(1): 385-394.
- [23] 马静, 刘功聚, 王健. 肌肉疲劳的阵列式表面肌电特征研究与展望[J]. 中华物理医学与康复杂志, 2018, 40(4): 318-320.
- [24] 程凤伟, 王文剑, 张珍珍. 面向高维小样本数据的层次子空间 ReliefF 特征选择算法[J]. 南京大学学报(自然科学), 2023, 59(6): 928-936.
- [25] 张鑫, 刁麓弘, 南东. 基于主成分分析的自适应特征选择算法研究[J]. 图学学报, 2018, 39(3): 501-508.

- [26] 张秀莲, 张芳, 周暖. 基于互信息的含水岩石近红外光谱特征选择[J]. 光谱学与光谱分析, 2021, 41(7): 2028-2035.
- [27] Moslemi A. A tutorial-based survey on feature selection: Recent advancements on feature selection[J]. Engineering Applications of Artificial Intelligence, 2023, 126: 107136.
- [28] 张梦婷, 杜建强, 罗计根. 多目标优化特征选择研究综述[J]. 计算机工程与应用, 2023, 59(3): 23-32.
- [29] SINDHWANI V, RAKSHIT S, DEODHARE D. Feature selection in MLPs and SVMs based on maximum output information[J]. IEEE Transactions on Neural Networks, 2004, 15(4): 937-948.
- [30] Liu Z, Yang J, Wang L. A novel relation aware wrapper method for feature selection[J]. Pattern Recognition, 2023, 140: 109566.
- [31] 姜照昶, 苏宇, 丁凯孟. 群体智能计算的多学科方法研究进展[J]. 计算机与数字工程, 2019, 47(12): 3053-3058.
- [32] Samieiyan B, MohammadiNasab P, Mollaei M A. Novel optimized crow search algorithm for feature selection[J]. Expert Systems with Applications, 2022, 204: 117486.
- [33] Souza V L F, Oliveira A L I, Cruz R M O. Improving BPSO-based feature selection applied to offline WI handwritten signature verification through overfitting control[C]//Proceedings of the 2020 Genetic and Evolutionary Computation Conference Companion. 2020: 69-70.
- [34] Yu X, Wang H, Lu Y. An adaptive ranking moth flame optimizer for feature selection[J]. Mathematics and Computers in Simulation, 2024, 219: 164-184.
- [35] Xue Y, Zhu H, Neri F. A feature selection approach based on NSGA-II with ReliefF[J]. Applied Soft Computing, 2023, 134: 109987.
- [36] Englehart K, Hudgins B. A robust, real-time control scheme for multifunction myoelectric control[J]. IEEE transactions on biomedical engineering, 2003, 50(7): 848-854.
- [37] MathWorks. Measurements and Feature Extraction[EB/OL]. 2023[2023-10-15]. https://www.mathworks.com/help/signal/measurements-and-feature-extraction_zh_CN.html.
- [38] 黄虎, 谢洪波. 基于蚁群算法的表面肌电信号特征选择[J]. 北京生物医学工程, 2012, (2): 164-169.
- [39] 施启军, 潘峰, 龙福海. 特征选择方法研究综述[J]. 微电子学与计算机, 2022,

- 39(3): 1-8.
- [40] Gong W, Cai Z. Differential evolution with ranking-based mutation operators[J]. IEEE Transactions on Cybernetics, 2013, 43(6): 2066-2081.
- [41] Rajaguru H, Prabhakar S K. KNN classifier and K-means clustering for robust classification of epilepsy from EEG signals. A detailed analysis[M]. diplom. de, 2017.
- [42] Mullick S, Datta S, Das S. Adaptive learning-based k-nearest neighbor classifiers with resilience to class imbalance[J]. IEEE transactions on neural networks and learning systems, 2018, 29(11): 5713-5725.
- [43] Wen J, Zhao Y, Rong Q. Rapid odor recognition based on reliefF algorithm using electronic nose and its application in fruit identification and classification[J], 2022, 16(3): 2422-2433.
- [44] ST. STM32F103: 相关 PDF 文档 [EB/OL]. [2024]. <https://www.st.com/zh/microcontrollers-microprocessors/stm32f103/documentation.html>.
- [45] Analog Devices. AD8236 Datasheet and Product Info[EB/OL]. [2024]. <https://www.analog.com/en/products/ad8236.html>.
- [46] Analog Devices. AD8646 Datasheet and Product Info[EB/OL]. [2024]. <https://www.analog.com/en/products/ad8646.html>.
- [47] Cheng L, Li J, Guo A. Recent advances in flexible noninvasive electrodes for surface electromyography acquisition[J]. npj Flexible Electronics, 2023, 7(1): 39.
- [48] 徐梦阳, 李昂, 赵峰. 基于 Labview 的 Modbus 通信协议串口上位机的实现[J]. 电子世界, 2020, (22):93-95.
- [49] 吴焕瑞, 车紫辉. C#.NET 调用 MATLAB 进行混合编程[J]. 电脑学习, 2010, (4).
- [50] 周涛, 徐晓. 基于 SQL Server 与 C#的图书管理系统的设计与开发[J]. 智能计算机与应用, 2018, 8(4): 199-202.
- [51] Xue L C, Noor A M, Zakaria Z. Neurorehabilitation Robot-Assisted for Stroke Recovery: Hybrid Exoskeleton Assistive Limb (HEAL)[J]. Indonesian Journal of Electrical Engineering and Informatics (IJEI), 2023, 11(4): 1143-1154.
- [52] 李强, 杨基海, 赵章琰. 基于匹配实测表面肌电信号的模型参数辨识 (英文)[J]. 航天医学与医学工程, 2007, 20(6): 391-397.
- [53] 张日辉, 康志新. 女子拳击运动员上肢和腰部肌肉力量训练的肌电分析[J]. 中国应用生理学杂志, 2011, 27(2): 253-256.